

· 2027 统计学复习指导书 ·

A2. 统计数据分析知识点

方差分析、相关分析

一元回归分析、多元回归分析

应用多元统计分析

抽样技术

应用时间序列分析

非参数统计



洛屿

学术交流中心

2026.5

目 录

第 1 章 方差分析、相关分析与回归分析	1
一、方差分析 ANOVA 的基本概念	
二、单因子方差分析	
三、多重比较问题	
四、方差齐性检验	
五、相关分析与回归分析	
 第 2 章 一元线性回归	 7
一、一元线性回归模型	
二、回归方程显著性检验	
三、区间预测与控制	
四、违背基本假设的情况	
 第 3 章 多元线性回归	 17
一、多元线性回归模型	
二、回归方程显著性检验	
三、区间预测	
四、自变量选择	
五、违背基本假设的情况	
六、多重共线性: $r(X) < p + 1$	
 第 4 章 非线性回归与定性变量回归	 30
一、曲线回归	
二、自变量含定性变量的回归模型	
三、因变量含定性变量的回归模型	
 第 5 章 多元正态分布	 33
一、随机向量及其性质	
二、多元正态分布	
三、多元正态分布的参数估计	
四、多元正态分布的假设检验	

第 6 章 判别分析与聚类分析	41
一、判别分析的基本思想	
二、距离判别	
三、Bayes 判别	
四、Fisher 判别	
五、逐步判别	
六、聚类分析的基本思想	
七、系统聚类法	
八、K-均值法	
九、有序样本聚类	
十、模糊聚类分析	
 第 7 章 主成分分析与因子分析	 54
一、主成分分析的基本思想	
二、主成分的求解与性质	
三、主成分分析的一般理论	
四、因子分析的基本思想	
五、因子载荷矩阵的求解与性质	
六、主成分分析与因子分析的区别	
 第 8 章 对应分析与典型相关分析	 63
一、对应分析的基本思想	
二、对应分析	
三、典型相关分析的基本思想	
四、典型相关变量的求解与检验	

第 1 章 方差分析、相关分析与回归分析

一、方差分析 ANOVA 的基本概念

1. 因子：所要检验的对象，影响实验结果的因素.
2. 水平：因子的不同表现.
3. 总误差：全部观测数据的误差；
 处理误差（组间误差）：由于不同处理造成的误差；
 随机误差（组内误差）：由于随机因素造成的误差.
4. 方差分析的基本假定：
 - (1) 正态性：每个总体都服从正态分布 $N(\mu_i, \sigma_i^2)$ ，对于因素的每一个水平的观察值是来自正态分布总体的简单随机样本；
 - (2) 方差齐性：每个总体的方差 σ_i^2 相同，均为 σ^2 ；
 - (3) 独立性：观察值是独立的.

二、单因子方差分析

1. 单因子试验：

设检验对象为因子 A ，有 r 个水平 $A_1, \dots, A_r$ ，在每个水平下都是总体 $N(\mu_i, \sigma^2)$ ， $i = 1, \dots, r$.

2. 单因子方差分析模型：

(1) 水平效应：

设在第 i 个水平下的总体中抽取的 m 个样本结果为： $y_{i1}, y_{i2}, \dots, y_{im}$ ，则一共可以得到 $r \times m$ 个结果 y_{ij} ，其中 r 为水平数， m 为重复数. 定义随机误差 $\varepsilon_{ij} = y_{ij} - \mu_i$ ，对于总均值

$$\mu = \frac{\mu_1 + \dots + \mu_r}{r}$$

因子 A 的第 i 个水平 A_i 的水平效应为

$$a_i = \mu_i - \mu$$

(2) 统计模型：

$$\begin{cases} \text{数据结构式: } y_{ij} = \mu + a_i + \varepsilon_{ij} \\ \text{水平效应零和: } a_1 + \dots + a_r = 0 \\ \text{正态性: } \varepsilon_{ij} \text{ 相互独立同 } N(0, \sigma^2) \end{cases}$$

【例题 1】阐述数据结构式 $y_{ij} = \mu_i + \varepsilon_{ij} = \mu + a_i + \varepsilon_{ij}$ 的含义.

3. 单因子方差分析的试验数据：

因子水平	试验数据				求和	均值
A_1	y_{11}	y_{12}	$\cdots$	y_{1m}	T_1	$\bar{y}_1$
A_2	y_{21}	y_{22}	$\cdots$	y_{2m}	T_2	$\bar{y}_2$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
A_r	y_{r1}	y_{r2}	$\cdots$	y_{rm}	T_r	$\bar{y}_r$
					T	$\bar{y}$

4. 单因子方差分析的偏差分析:

(1) 偏差分解:

$$y_{ij} - \bar{y} = (y_{ij} - \bar{y}_i) + (\bar{y}_i - \bar{y})$$

其中, $y_{ij} - \bar{y}_i$ 称为组内偏差, 反映组内数据与组内均值的随机误差;

$\bar{y}_i - \bar{y}$ 称为组件偏差, 反映组内均值与全局均值的随机误差, 并反映 A_i 的水平效应.

【例题 2】通过对偏差分解解释 y_{ij} 的误差来源.

(2) 偏差平方和: 偏差平方和 Q 用于度量若干个数据的离散程度、波动大小.

$$Q = \sum_{i=1}^k (y_i - \bar{y})^2$$

【例题 3】求证: 偏差平方和的自由度 $f_Q = k - 1$.

总偏差平方和 SST : 每个试验结果数据 y_{ij} 间的差异记作, 即

$$SST = \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y})^2$$

组内偏差平方和 SSE : 仅由随机误差引起的数据间的差异, 即

$$SSE = \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y}_i)^2$$

组间偏差平方和 SSA : 由随机误差和 A_i 的水平效应引起的数据间的差异, 即

$$SSA = \sum_{i=1}^r \sum_{j=1}^m (\bar{y}_i - \bar{y})^2 = m \sum_{i=1}^r (\bar{y}_i - \bar{y})^2$$

【例题 4】求证: $f_T = n - 1, f_E = n - r, f_A = r - 1$.

(3) 总偏差平方和分解:

$$SST = SSE + SSA$$

【例题 5】求证: $SST = SSE + SSA$.

5. 单因子方差分析模型基本定理:

(1) $\frac{SSE}{\sigma^2} \sim \chi^2(n-r);$

(2) SSA 与 SSE 相互独立;

(3) $E(SSA) = (r-1)\sigma^2 + m \sum_{i=1}^r a_i^2.$

【例题 6】求证: 单因子方差分析模型基本定理.

6. 单因子方差分析的检验:

(1) 检验假设:

$$H_0: \mu_1 = \mu_2 = \cdots = \mu_r$$

同时等价于

$$H_0: a_1 = a_2 = \cdots = a_r = 0$$

(2) 检验统计量:

$$F = \frac{SSA/f_A}{SSE/f_E}$$

(3) 拒绝域:

$$W = \{F \geq F_{1-\alpha}(f_A, f_E)\}$$

7. 单因子方差分析表:

方差来源	偏差平方和	自由度	均方	F值
因子	SSA	$r-1$	$MSA = SSA/f_A$	$F = \frac{MSA}{MSE}$
误差	SSE	$n-r$	$MSE = SSE/f_E$	
总偏差	SST	$n-1$		

8. 重复数不同的单因子方差分析:

设在第*i*个水平下的总体中抽取的*m*个样本结果为: $y_{i1}, y_{i2}, \dots, y_{im_i}$, 其中 $m_1 + \cdots + m_r = n$

$$\left\{ \begin{array}{l} \text{数据结构式: } y_{ij} = \mu + a_i + \varepsilon_{ij} \\ \text{水平效应零和: } m_1 a_1 + \cdots + m_r a_r = 0 \\ \text{正态性: } \varepsilon_{ij} \text{ 相互独立同 } N(0, \sigma^2) \end{array} \right.$$

$$SST = \sum_{i=1}^r \sum_{j=1}^{m_i} (y_{ij} - \bar{y})^2 = \sum_{i=1}^r \sum_{j=1}^{m_i} y_{ij}^2 - \frac{T^2}{n}, \quad SSA = \sum_{i=1}^r \sum_{j=1}^{m_i} (\bar{y}_i - \bar{y})^2 = \sum_{i=1}^r \frac{T_i^2}{m_i} - \frac{T^2}{n}$$

$$SSE = SST - SSA$$

三、多重比较问题

1. 多重比较问题：若因子A通过单因子方差分析，即A的 r 个水平不完全相同. 在 r 个水平均值中同时任意比较两个水平均值之间的差异，即同时在显著性水平 α 下检验 $\frac{r(r-1)}{2}$ 个假设：

$$H_0^{ij}: \mu_i = \mu_j, \quad 1 \leq i < j \leq r$$

【例题 7】阐述多重比较问题不能用 $\frac{r(r-1)}{2}$ 个检验分别进行检验的原因.

2. 多重比较检验的拒绝域：

$$W = \bigcup_{1 \leq i < j \leq r} \{|\bar{y}_i - \bar{y}_j| \geq c_{ij}\}$$

使得在 H_0 下有 $P(W) = \alpha$.

3. 重复数相同的多重比较：

由重复数相同，则 c_{ij} 应相同，记为 c ，检验统计量

$$t_i = \frac{\bar{y}_i - \mu_i}{\sqrt{\frac{SSE}{f_E}} / \sqrt{m}} \sim t(f_E)$$

则拒绝域

$$P\left(\bigcup_{1 \leq i < j \leq r} \{|\bar{y}_i - \bar{y}_j| \geq c\}\right) = P\left(\max_i \frac{\bar{y}_i - \mu}{\sqrt{\frac{SSE}{f_E}} / \sqrt{m}} - \min_j \frac{\bar{y}_j - \mu}{\sqrt{\frac{SSE}{f_E}} / \sqrt{m}} \geq \frac{c}{\sqrt{\frac{SSE}{f_E}} / \sqrt{m}}\right) = \alpha$$

其中， $q(r, f_E) = \max_i \frac{\bar{y}_i - \mu}{\sqrt{\frac{SSE}{f_E}} / \sqrt{m}} - \min_j \frac{\bar{y}_j - \mu}{\sqrt{\frac{SSE}{f_E}} / \sqrt{m}}$ 称为 t 化极差统计量，从而

$$c = q_{1-\alpha}(r, f_E) \sqrt{\frac{SSE}{f_E}} / \sqrt{m}$$

【例题 8】求证： $P(W) = P\left(q(r, f_E) \geq \frac{c}{\sqrt{\frac{SSE}{f_E}} / \sqrt{m}}\right)$.

*结论：对给定的显著性水平 α ，查表求 c ，若对 $\forall i, j$ 有 $|\bar{y}_i - \bar{y}_j| \geq c$ ，则认为水平 A_i 与水平 A_j 之间有显著差异.

4. 重复数不同的多重比较:

由 $\frac{(\bar{y}_i - \bar{y}_j) - (\mu_i - \mu_j)}{\sqrt{\frac{1}{m_i} + \frac{1}{m_j}} \sqrt{\frac{SSE}{f_E}}} \sim t(f_E)$, 检验统计量

$$F_{ij} = \frac{(\bar{y}_i - \bar{y}_j)^2}{\left(\frac{1}{m_i} + \frac{1}{m_j}\right) \frac{SSE}{f_E}} \sim F(1, f_E)$$

则拒绝域

$$P(W) = P\left(\bigcup_{1 \leq i < j \leq r} \left\{ |\bar{y}_i - \bar{y}_j| \geq c \sqrt{\frac{1}{m_i} + \frac{1}{m_j}} \right\}\right) = P\left(\max_{1 \leq i < j \leq r} F_{ij} \geq \frac{c^2}{\frac{SSE}{f_E}}\right) = \alpha$$

由 $\frac{\max_{1 \leq i < j \leq r} F_{ij}}{r-1} \sim F(r-1, f_E)$, 从而

$$c_{ij} = \sqrt{(r-1)F_{1-\alpha}(r-1, f_E) \left(\frac{1}{m_i} + \frac{1}{m_j}\right) \frac{SSE}{f_E}}$$

四、方差齐性检验

1. 方差齐性检验问题:

$$H_0: \sigma_1^2 = \dots = \sigma_r^2$$

2. 重复数相同的方差齐性检验: (Hartley 检验)

(1) 检验统计量:

$$H = \frac{\max\{S_1^2, \dots, S_r^2\}}{\min\{S_1^2, \dots, S_r^2\}} \sim H(r, m-1)$$

(2) 拒绝域:

$$W = \{H \geq H_{1-\alpha}(r, m-1)\}$$

3. 重复数不同的方差齐性检验: (Bartlett 检验, 样本量大于5)

(1) 检验统计量:

$$B = \frac{f_E \ln \frac{MSE}{[(S_1^2)^{f_1} \dots (S_r^2)^{f_r}]^{\frac{1}{f_E}}}}{C} \sim \chi^2(r-1)$$

其中, $C = 1 + \frac{1}{3(r-1)} \left(\frac{1}{f_1} + \dots + \frac{1}{f_r} - \frac{1}{f_E} \right)$.

(2) 拒绝域:

$$W = \{B \geq \chi_{1-\alpha}^2(r-1)\}$$

4. 重复数不同的方差齐性检验: (Box 检验)

*上述重复数不同的方差齐性检验构造的检验统计量的分布是近似分布.

五、相关分析与回归分析

1. 相关分析与回归分析的区别：

	相关分析	回归分析
X 与 Y 的性质	均为随机变量	Y 是随机变量， X 可以是随机或非随机变量
X 与 Y 的关系	平等地位	Y 是因变量， X 是自变量， Y 被 X 解释
应用目的	刻画线性相关程度	对 Y 进行预测和控制

2. 回归函数：条件期望

$$y = f(x) = E(Y|x) = \int_{-\infty}^{+\infty} y f(y|x) dy$$

理论回归方程：

$$y = \alpha + \beta x$$

经验回归方程：

$$\hat{y} = \hat{\alpha} + \hat{\beta} x$$

3. 回归模型：

$$y = f(x_1, x_2, \dots, x_p) + \varepsilon$$

其中， $f(x_1, x_2, \dots, x_p)$ 是确定性函数， ε 是随机误差项，包括：

- ①未引入但对回归被解释变量 y 有影响的因素；
- ②观测误差；
- ③模型设定误差.

4. 线性回归模型：

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \varepsilon_i, \quad i = 1, 2, \dots, n$$

基本假设：

- (1) $x_1, \dots, x_p$ 是非随机变量， $n > p$ ， $r(X) = p + 1 < n$ ；
- (2) Gauss-Markov 假设：随机误差项0期望、等方差、不相关：

$$\begin{cases} E(\varepsilon_i) = 0 \\ \text{cov}(\varepsilon_i, \varepsilon_j) = \begin{cases} \sigma^2, & i = j \\ 0, & i \neq j \end{cases} \end{cases}$$

- (3) 正态分布假设：随机误差项独立同分布 $\varepsilon_i \sim N(0, \sigma^2)$.

【例题 9】阐述线性回归模型基本假设的含义.

第2章 一元线性回归


一、一元线性回归模型

1. 一元线性回归模型: $y = \beta_0 + \beta_1 x + \varepsilon$

一元线性回归方程: $E(y|x) = \beta_0 + \beta_1 x$

一元线性样本回归模型: $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

一元线性经验回归方程: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$



【例题 1】求证：在正态假定下，一元线性样本回归模型 y_i 相互独立，但分布不同。

2. 普通最小二乘估计 β_0, β_1 : (OLSE)

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{L_{xy}}{L_{xx}} \end{cases}$$

【例题 2】求证：普通最小二乘估计 β_0, β_1 的表达式。

【例题 3】求证：在正态假定前提下，最大似然估计与最小二乘估计 β_0, β_1 等价。

【例题 4】求证:
$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

3. 估计量 $\hat{\beta}_0, \hat{\beta}_1$ 的性质:

(1) 回归直线 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 过样本中心 $(\bar{x}, \bar{y})$.

【例题 5】求证: 上述命题成立, 并简述该性质的意义.

(2) $\hat{\beta}_0, \hat{\beta}_1$ 是 y_i 的线性组合: $\hat{\beta}_1 = \sum_{i=1}^n \frac{x_i - \bar{x}}{L_{xx}} y_i$, $\hat{\beta}_0 = \sum_{i=1}^n \left(\frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{L_{xx}} \right) y_i$.

【例题 6】求证: 上述命题成立, 并简述该性质的意义.

(3) $\hat{\beta}_0, \hat{\beta}_1$ 是 β_0, β_1 的无偏估计: $E(\hat{\beta}_1) = \beta_1$, $E(\hat{\beta}_0) = \beta_0$.

【例题 7】求证: 上述命题成立, 并简述该性质的意义.

(4) $\hat{\beta}_0, \hat{\beta}_1$ 是 β_0, β_1 的最小方差无偏估计: $D(\hat{\beta}_1) = \frac{1}{L_{xx}} \sigma^2$, $D(\hat{\beta}_0) = \left(\frac{1}{n} + \frac{\bar{x}^2}{L_{xx}} \right) \sigma^2$.

【例题 8】求证: 上述命题成立, 并简述该性质的意义.

(5) $\hat{\beta}_1 \sim N\left(\beta_1, \frac{1}{L_{xx}} \sigma^2\right)$, $\hat{\beta}_0 \sim N\left(\beta_0, \left(\frac{1}{n} + \frac{\bar{x}^2}{L_{xx}}\right) \sigma^2\right)$, $\text{cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}}{L_{xx}} \sigma^2$.

【例题 9】求证: 上述命题成立, 并简述该性质的意义.

4. 拟合值 $\hat{y}$ 的性质: $\hat{y}$ 是 y_i 的线性组合, 是 $E(y)$ 的无偏估计, $\hat{y} \sim N\left(\beta_0 + \beta_1 x, \left(\frac{1}{n} + \frac{(x-\bar{x})^2}{L_{xx}}\right)\sigma^2\right)$.

【例题 10】求证: 上述命题成立, 并简述该性质的意义.

5. 残差 e_i 的性质:

(1) $E(e_i) = 0$, $D(e_i) = \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{L_{xx}}\right)\sigma^2 = (1 - h_{ii})\sigma^2$, 其中 h_{ii} 称为杠杆值.

【例题 11】求证: 上述命题成立.

(2) $\sum_{i=1}^n e_i = 0$, $\sum_{i=1}^n x_i e_i = 0$.

【例题 12】求证: 上述命题成立, 并简述该性质的意义.

6. 离差平方和分解:

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

【例题 13】求证: 离差平方和分解 $SST = SSR + SSE$, 并分别解释各成分的含义.

7. 误差方差 σ^2 的性质:

(1) $\hat{\sigma}^2 = \frac{SSE}{n-2}$ 是 σ^2 的无偏估计.

【例题 14】 求证: 上述命题成立.

(2) $\hat{\sigma}^2$ 与 $\hat{\beta}_0, \hat{\beta}_1$ 均相互独立.

【例题 15】 求证: 上述命题成立.

(3) $\frac{(n-2)\hat{\sigma}^2}{\sigma^2} = \frac{SSE}{\sigma^2} \sim \chi^2(n-2), \frac{SSR}{\sigma^2} \sim \chi^2(1).$

【例题 16】 求证: 上述命题成立.

二、回归方程显著性检验

1. 回归系数显著性检验：检验自变量 x 对因变量 y 的线性影响程度是否显著.

检验假设：

$$H_0: \beta_1 = 0 \leftrightarrow H_1: \beta_1 \neq 0$$

检验统计量：

$$t = \frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}/\sqrt{L_{xx}}} \stackrel{\text{在} H_0 \text{下}}{\sim} t(n-2)$$

t 值拒绝域：当 $|t| \geq t_{\frac{\alpha}{2}}(n-2)$ 时，拒绝 H_0 ，认为 y 对 x 的一元线性回归成立.

p 值拒绝域：当 $P(|t| \geq |t|) \leq \alpha$ 时，拒绝 H_0 ，认为 y 对 x 的一元线性回归成立.

【例题 17】求证：在 H_0 下， $t \sim t(n-2)$.

2. 回归效果显著性检验：检验能够由自变量 x 对因变量 y 的线性解释部分的占比是否显著.

检验假设：

$$H_0: \beta_1 = 0 \leftrightarrow H_1: \beta_1 \neq 0$$

检验统计量：

$$F = \frac{SSR/1}{SSE/(n-2)} \stackrel{\text{在} H_0 \text{下}}{\sim} F(1, n-2)$$

F 值拒绝域：当 $F \geq F_{\alpha}(1, n-2)$ 时，拒绝 H_0 ，认为 x 与 y 有显著的线性关系.

p 值拒绝域：当 $P(F \geq F) \leq \alpha$ 时，拒绝 H_0 ，认为 x 与 y 有显著的线性关系.

【例题 18】求证：在 H_0 下， $F \sim F(1, n-2)$.

3. Pearson 相关系数显著性检验：反映两个变量间的线性相关性.

检验假设：

$$H_0: r = 0 \leftrightarrow H_1: r \neq 0$$

检验统计量：

$$t = \frac{\sqrt{n-2} r}{\sqrt{1-r^2}} \stackrel{\text{在} H_0 \text{下}}{\sim} t(n-2) \quad \text{其中, } r = \frac{L_{xy}}{\sqrt{L_{xx}}\sqrt{L_{yy}}}$$

t 值拒绝域：当 $|t| \geq t_{\frac{\alpha}{2}}(n-2)$ 时，拒绝 H_0 ，认为 y 对 x 的 Pearson 相关系数显著不为0.

p 值拒绝域：当 $P(|t| \geq |t|) \leq \alpha$ 时，拒绝 H_0 ，认为 y 对 x 的 Pearson 相关系数显著不为0.

【例题 19】求证：在 H_0 下， $t \sim t(n-2)$.

4. 拟合优度检验：

回归平方和在总离差平方和中所占的比重越大，则线性回归效果越好，说明回归直线与样本观测值的拟合优度越好. 判定系数：

$$R^2 = \frac{SSR}{SST}$$

【例题 20】求证：在基于最小二乘的线性回归模型中，判定系数 R^2 与相关系数 r^2 等价.

【例题 21】说明相关系数 r^2 与判定系数 R^2 在使用时的局限性.

5. 回归系数 t 检验、回归方程 F 检验、Pearson 相关系数检验的关系：

对于一元线性回归，三种显著性检验等价.

【例题 22】完成下表：

显著性检验	检验内容	统计量	拒绝域
t 检验			
F 检验			
相关系数			
拟合优度			

三、区间预测与控制

1. 回归系数 β_0, β_1 的区间估计:

$$P\left(\hat{\beta}_1 - \frac{\hat{\sigma}}{\sqrt{L_{xx}}} t_{\frac{\alpha}{2}}(n-2) < \beta_1 < \hat{\beta}_1 + \frac{\hat{\sigma}}{\sqrt{L_{xx}}} t_{\frac{\alpha}{2}}(n-2)\right) = 1 - \alpha$$
$$P\left(\hat{\beta}_0 - \hat{\sigma} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{L_{xx}}} t_{\frac{\alpha}{2}}(n-2) < \beta_0 < \hat{\beta}_0 + \hat{\sigma} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{L_{xx}}} t_{\frac{\alpha}{2}}(n-2)\right) = 1 - \alpha$$

2. 区间预测问题:

对于显著性水平 α , 求区间 (T_1, T_2) 使得对于 x_i 的预测值 $\hat{y}_i$ 满足 $P(T_1 < \hat{y}_i < T_2) = 1 - \alpha$.

(1) 因变量预测值 $\hat{y}_i$ 的区间预测:

$$(T_1, T_2) = \left(\hat{y}_i - \hat{\sigma} \sqrt{1 + h_{ii}} t_{\frac{\alpha}{2}}(n-2), \hat{y}_i + \hat{\sigma} \sqrt{1 + h_{ii}} t_{\frac{\alpha}{2}}(n-2)\right)$$

【例题 23】推导因变量预测值 $\hat{y}_i$ 的区间, 并说明提高预测精度的方案.

(2) 因变量预测值 $\hat{y}_i$ 平均值 $E(\hat{y}_i)$ 的区间预测:

$$(T_1, T_2) = \left(\hat{y}_i - \hat{\sigma} \sqrt{h_{ii}} t_{\frac{\alpha}{2}}(n-2), \hat{y}_i + \hat{\sigma} \sqrt{h_{ii}} t_{\frac{\alpha}{2}}(n-2)\right)$$

【例题 24】推导因变量预测值 $\hat{y}_i$ 平均值 $E(\hat{y}_i)$ 的区间.

3. 控制问题: 对于给定 $P(T_1 < y < T_2) = 1 - \alpha$, 求 x 的取值区间 (S_1, S_2) .

取 $\alpha = 0.05$, 当样本量 n 较大, $|x_i - \bar{x}|$ 较小时, $h_{ii} \approx 0$, 此时 $(T_1, T_2) = (\hat{y}_i - 2\hat{\sigma}, \hat{y}_i + 2\hat{\sigma})$,

由 $\begin{cases} \hat{y}(x) - 2\hat{\sigma} > T_1 \\ \hat{y}(x) + 2\hat{\sigma} < T_2 \end{cases}$, 带入 $\hat{y}(x) = \hat{\beta}_0 + \hat{\beta}_1 x$ 近似求出 x 的取值区间:

$$(S_1, S_2) = \begin{cases} \left(\frac{T_1 + 2\hat{\sigma} - \hat{\beta}_0}{\hat{\beta}_1}, \frac{T_2 - 2\hat{\sigma} - \hat{\beta}_0}{\hat{\beta}_1}\right), & \hat{\beta}_1 > 0 \\ \left(\frac{T_2 - 2\hat{\sigma} - \hat{\beta}_0}{\hat{\beta}_1}, \frac{T_1 + 2\hat{\sigma} - \hat{\beta}_0}{\hat{\beta}_1}\right), & \hat{\beta}_1 < 0 \end{cases}$$


四、违背基本假设的情况

1. 异常值: $E(\varepsilon_i) \neq 0$

(1) 判断异常值的方法:

①残差图:

回归模型满足所给出的基本假定时, 所有残差应在 $e = 0$ 附近随机变化, 并在变化幅度不大的一个区域内.



②标准化残差与学生化残差:

将残差进行标准化、学生化后便于比较, 从而判断异常值.

$$|ZRE_i| = \left| \frac{e_i}{\hat{\sigma}} \right| > 3 \quad |SRE_i| = \left| \frac{e_i}{\hat{\sigma}\sqrt{1-h_{ii}}} \right| > 3$$

③删除残差与学生化删除残差:

用删掉第 i 个观测值的其余 $n-1$ 个观测值拟合回归方程, 若第 i 个观测值的拟合值为 $\hat{y}_{(i)}$,

则删除残差为 $e_{(i)} = y_i - \hat{y}_{(i)} = \frac{e_i}{1-h_{ii}}$, 用学生化删除残差可判断异常值:

$$|SRE_{(i)}| = \left| SRE_i \sqrt{\frac{n-3}{n-2-SRE_i^2}} \right| > 3$$

【例题 25】说明删除残差对于标准化残差、学生化残差的改进之处.

④强影响点:

杠杆值大的观测点远离样本中心, 把回归方程拉向自身, 残差偏小, 称为强影响点. 强影响点不一定是 y 的异常值点, 但是对回归效果有较强影响, 用 Cook 距离可判断强影响点:

$$D_i = \frac{e_i^2}{2\hat{\sigma}^2} \frac{h_{ii}}{(1-h_{ii})^2} > 1$$

对于强影响点, 利用中心化杠杆值可判断异常值:

$$ch_{ii} = h_{ii} - \frac{1}{n} > 2\overline{ch} = \frac{2}{n}$$

(2) 异常值产生的原因与消除异常值的方法:


异常值产生的原因	消除异常值的方法
1. 数据登记误差, 存在抄写或录入的错误	重新核实数据
2. 数据测量误差	重新测量数据
3. 数据随机误差	删除或重新观测异常值数据
4. 缺少重要自变量	增加必要的自变量
5. 缺少观测数据	增加观测数据, 适当扩大自变量取值范围
6. 存在异方差性	采用加权线性回归
7. 模型选用错误, 线性模型不适用	改用非线性回归模型

2. 异方差: $D(\varepsilon_i) \neq D(\varepsilon_j)$

(1) 判断异方差的方法:

①残差图:

残差 e 值随 x 值的增大而增大或减小,
残差图上点的散布呈现明显的趋势.



②Spearman 相关系数检验:

将 x_i 和 $|e_i|$ 按递增或递减次序排列后分成等级, 计算等级相关系数:

$$r_s = 1 - \frac{6}{n(n^2 - 1)} \sum_{i=1}^n d_i^2$$

其中, d_i 为 x_i 与 $|e_i|$ 的等级差数, 即秩统计量之差.

检验假设:

$$H_0: r_s = 0 \leftrightarrow H_1: r_s \neq 0$$

检验统计量:

$$t = \frac{\sqrt{n-2} r_s}{\sqrt{1-r_s^2}} \stackrel{\text{在 } H_0 \text{ 下}}{\sim} t(n-2)$$

t 值拒绝域: 当 $|t| \geq t_{\frac{\alpha}{2}}(n-2)$ 时, 拒绝 H_0 , 认为 Spearman 相关系数显著不为0, 有异方差.

p 值拒绝域: 当 $P(|t| \geq |t|) \leq \alpha$ 时, 拒绝 H_0 , 认为 Spearman 相关系数显著不为0, 有异方差.

(2) 异方差产生的原因:

某因素或某些因素会随着解释变量观测值的变化而对被解释变量产生不同的影响, 导致随机误差项产生不同方差. 当样本数据为横截面数据时容易出现异方差性.

(3) 消除异方差的方法: 加权最小二乘估计 (WLSE)

$$\begin{cases} \hat{\beta}_{0w} = \bar{y}_w - \hat{\beta}_{1w} \bar{x}_w \\ \hat{\beta}_{1w} = \frac{\sum_{i=1}^n w_i (x_i - \bar{x}_w) (y_i - \bar{y}_w)}{\sum_{i=1}^n w_i (x_i - \bar{x}_w)^2}, \text{ 其中 } \bar{x}_w = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}, \bar{y}_w = \frac{\sum_{i=1}^n w_i y_i}{\sum_{i=1}^n w_i} \end{cases}$$

为了消除异方差性的影响, 观测值的权数应该是观测值误差项方差的倒数: $\omega_i = \frac{1}{\sigma_i^2}$;

在社会经济研究中, 经常会遇到误差项方差与 x 的幂函数 x^m 成比例, 故权数为 $\omega_i = \frac{1}{x_i^m}$.

*加权最小二乘估计的局限性:

加权最小二乘估计不一定会得到与普通最小二乘估计截然不同的回归方程, 结果不一定有大幅改进; 可以构造出回归模型存在很强的异方差性, 但普通最小二乘与加权最小二乘所得的回归方程完全一样的数据.


加权最小二乘是以牺牲大方差项的拟合效果为代价改善了小方差项的拟合效果, 在特定场合, 即使数据存在异方差性, 也可以选择使用普通最小二乘估计.

3. 自相关: $\text{cov}(\varepsilon_i, \varepsilon_j) \neq 0$

(1) 判断自相关的方法:

①残差图:

(e_t, e_{t-1}) 散点图序列正相关或负相关; 时间序列回归残差项 e_t 呈现锯齿状或循环形状变化.




②自相关系数与 DW 检验:

只适用于检验随机扰动项具有一阶自回归形式的序列相关问题, 其形式为: $\varepsilon_t = \rho\varepsilon_{t-1} + \varepsilon'_t$
检验假设:

$$H_0: \rho = 0 \leftrightarrow H_1: \rho \neq 0$$

检验统计量:

$$DW = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=2}^n e_t^2} \approx 2(1 - \hat{\rho}) \quad \text{其中, } \rho = \frac{\sum_{t=2}^n \varepsilon_t \varepsilon_{t-1}}{\sqrt{\sum_{t=2}^n \varepsilon_t^2} \sqrt{\sum_{t=2}^n \varepsilon_{t-1}^2}} \quad \hat{\rho} = \frac{\sum_{t=2}^n e_t e_{t-1}}{\sqrt{\sum_{t=2}^n e_t^2} \sqrt{\sum_{t=2}^n e_{t-1}^2}}$$



【例题 26】说明 DW 检验的局限性.

(2) 自相关产生的原因:

- ①建模中遗漏具有相关性的关键变量; ②经济变量滞后性使顺序观测值之间存在相关性;
- ③建模中使用错误的回归函数形式; ④经济学中的蛛网现象; ⑤不恰当的数据预处理.

(3) 消除自相关的方法:

①迭代法:

$$\text{由} \begin{cases} y_t = \beta_0 + \beta_1 x_t + \varepsilon_t \\ y_{t-1} = \beta_0 + \beta_1 x_{t-1} + \varepsilon_{t-1} \end{cases} \Rightarrow (y_t - \rho y_{t-1}) = (\beta_0 - \rho \beta_0) + \beta_1 (x_t - \rho x_{t-1}) + (\varepsilon_t - \rho \varepsilon_{t-1}),$$

代换得: $y'_t = \beta'_0 + \beta_1 x'_t + \varepsilon'_t$, 其中 ε'_t 满足基本假定, 从而可以进行普通最小二乘估计.

对于误差项不是一阶自相关的情况, 要进行反复迭代和 DW 检验, 直至消除误差项自相关.

②差分法:

当自相关系数 $\rho \approx 1$ 时, 迭代法模型化为 $y'_t = \beta_1 x'_t + \varepsilon'_t$, 即差分模型 $\Delta y_t = \beta_1 \Delta x_t + \varepsilon'_t$, 有

$$\hat{\beta}_1 = \frac{\sum_{t=2}^n \Delta y_t \Delta x_t}{\sum_{t=2}^n \Delta x_t^2}$$

第3章 多元线性回归

一、多元线性回归模型

1. 多元线性回归模型: $y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon$

多元线性回归方程: $E(y) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$

多元线性样本回归模型:
$$\begin{cases} y_1 = \beta_0 + \beta_1 x_{11} + \cdots + \beta_p x_{1p} + \varepsilon_1 \\ \vdots \\ y_n = \beta_0 + \beta_1 x_{n1} + \cdots + \beta_p x_{np} + \varepsilon_n \end{cases} \Leftrightarrow y = X\beta + \varepsilon$$

其中, $y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$, $\beta = \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_p \end{bmatrix}$, $X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{bmatrix}$, $\varepsilon = \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$.

多元线性经验回归方程: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p$

【例题 1】求证: 在正态假定下, $y \sim N_n(X\beta, \sigma^2 E_n)$.

【例题 2】解释多元线性回归方程中回归系数 β_i 的含义.

2. 普通最小二乘估计 β : (OLSE)

$$\hat{\beta} = (X'X)^{-1}X'y$$

【例题 3】求证: 普通最小二乘估计 $\hat{\beta}$ 的表达式.

【例题 4】求证: 在正态假定前提下, 最大似然估计与最小二乘估计 β 等价.

3. 估计量 $\hat{\beta}$ 的性质:

(1) 回归超平面 $\hat{y} = X\hat{\beta}$ 过样本中心 $(\bar{x}_1, \dots, \bar{x}_p; \bar{y})$.

【例题 5】求证: 上述命题成立, 并简述该性质的意义.

(2) $\hat{\beta}$ 是 y 的一个线性变换: $\hat{y} = X\hat{\beta} = X(X'X)^{-1}X'y := Hy$, 其中, H 为对称投影矩阵.

【例题 6】求证: 上述命题成立, 并简述该性质的意义.

(3) $\hat{\beta}$ 是 β 的无偏估计: $E(\hat{\beta}) = \beta$.

【例题 7】求证: 上述命题成立.

(4) $\hat{\beta}$ 是 β 的最小方差无偏估计: $D(\hat{\beta}) = \sigma^2(X'X)^{-1}$.

【例题 8】求证: 上述命题成立, 并简述该性质的意义.

(5) $\hat{\beta} \sim N_{p+1}(\beta, \sigma^2(X'X)^{-1})$.

【例题 9】求证: 上述命题成立.

4. 残差 e 的性质:

(1) $E(e) = \mathbf{0}$, $D(e) = \sigma^2(E_n - H) \Leftrightarrow D(e_i) = (1 - h_{ii})\sigma^2$, 其中 h_{ii} 称为杠杆值.

【例题 10】求证: 上述命题成立.

(2) $He = \mathbf{0}$, $X'e = \mathbf{0} \Leftrightarrow \sum_{i=1}^n x_{ij}e_i = 0$, $j=1, \dots, p$.

【例题 11】求证: 上述命题成立, 并简述该性质的意义.

5. 离差平方和分解:

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

【例题 12】求证: 离差平方和分解 $SST = SSR + SSE$, 并分别解释各成分的含义.

6. 误差方差 σ^2 的性质:

(1) $\hat{\sigma}^2 = \frac{SSE}{n-p-1}$ 是 σ^2 的无偏估计.

【例题 13】求证: 上述命题成立.

(2) $\hat{\sigma}^2$ 与 $\hat{\beta}$ 相互独立.

【例题 14】求证: 上述命题成立.

(3) $\frac{(n-p-1)\hat{\sigma}^2}{\sigma^2} = \frac{SSE}{\sigma^2} \sim \chi^2(n-p-1)$, $\frac{SSR}{\sigma^2} \sim \chi^2(p)$.

【例题 15】求证: 上述命题成立.

二、回归方程显著性检验

1. 回归效果显著性检验：检验因变量 y 与自变量 X 之间是否存在显著的线性回归关系.

检验假设：

$$H_0: \beta_1 = \cdots = \beta_p = 0 \leftrightarrow H_1: \exists \beta_i \neq 0$$

检验统计量：

$$F = \frac{SSR/p}{SSE/(n-p-1)} \stackrel{\text{在} H_0 \text{下}}{\sim} F(p, n-p-1)$$

F 值拒绝域：当 F 值 $\geq F_\alpha(p, n-p-1)$ 时，拒绝 H_0 ，认为存在显著的线性回归关系.

p 值拒绝域：当 $P(F \geq F\text{值}) \leq \alpha$ 时，拒绝 H_0 ，认为存在显著的线性回归关系.

【例题 16】求证：在 H_0 下， $F \sim F(p, n-p-1)$

2. 回归系数显著性检验：检验单个自变量 x_i 对因变量 y 的线性影响程度是否显著.

检验假设：

$$H_{0i}: \beta_i = 0 \leftrightarrow H_{1i}: \beta_i \neq 0$$

检验统计量：

$$t_i = \frac{\hat{\beta}_i - \beta_i}{\hat{\sigma} \sqrt{c_{ii}}} \stackrel{\text{在} H_0 \text{下}}{\sim} t(n-p-1), \text{ 其中 } C = (X'X)^{-1}$$

t 值拒绝域：当 $|t\text{值}| \geq t_{\frac{\alpha}{2}}(n-p-1)$ 时，拒绝 H_0 ，认为 x_i 对 y 的线性效果显著.

p 值拒绝域：当 $P(|t| \geq |t\text{值}|) \leq \alpha$ 时，拒绝 H_0 ，认为 x_i 对 y 的线性效果显著.

【例题 17】求证：在 H_0 下， $t \sim t(n-p-1)$.

3. 拟合优度检验：

判定系数 $R^2 = \frac{SSR}{SST}$ ；复相关系数 R ：反映因变量 y 与一组自变量 X 的相关性.

4. 偏相关系数与偏判定系数：

(1) 偏相关系数：固定 $x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_{j-1}, x_{j+1}, \dots, x_p$ 不变， x_i 与 x_j 之间的偏相关系数为

$$r_{ij; x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_{j-1}, x_{j+1}, \dots, x_p} = -\frac{\Delta_{12}}{\sqrt{\Delta_{11}} \sqrt{\Delta_{22}}}$$

其中， Δ_{kl} 为样本相关矩阵 r 的第 k 行第 l 列元素 r_{kl} 的代数余子式.

(2) 偏判定系数：当模型中已经含有 $x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_p$ 时， y 对 x_p 的偏判定系数为

$$R_{yi; 1, \dots, i-1, i+1, \dots, p}^2 = \frac{SSE(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_p) - SSE(x_1, \dots, x_p)}{SSE(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_p)}$$

其中， $SSE(x_k)$ 为模型中仅含有自变量 x_k 时 y 的残差平方和.

【例题 18】说明偏相关系数对于 Pearson 相关系数之间的区别.

【例题 19】说明在多元线性回归显著性检验中, 回归系数 t 检验、回归方程 F 检验不等价, 并判断偏相关系数、偏判定系数与 t 值、 F 值之间的等价性.

三、区间预测

1. 回归系数 $\hat{\beta}$ 的区间估计:

$$P\left(\hat{\beta}_i - \hat{\sigma}\sqrt{c_{ii}}t_{\frac{\alpha}{2}}(n-p-1) < \beta_i < \hat{\beta}_i + \hat{\sigma}\sqrt{c_{ii}}t_{\frac{\alpha}{2}}(n-p-1)\right) = 1 - \alpha$$

2. 区间预测问题:

对于显著性水平 α , 求区间 (T_1, T_2) 使得对于 x_i 的预测值 $\hat{y}_i$ 满足 $P(T_1 < \hat{y}_i < T_2) = 1 - \alpha$.

$$(T_1, T_2) = \left(\hat{y}_i - \hat{\sigma}\sqrt{1 + x_i'(X'X)^{-1}x_i}t_{\frac{\alpha}{2}}(n-p-1), \hat{y}_i + \hat{\sigma}\sqrt{1 + x_i'(X'X)^{-1}x_i}t_{\frac{\alpha}{2}}(n-p-1)\right)$$

四、自变量选择

1. 全模型与选模型的定义:

设研究问题所涉及的变量有 m 个, 由因变量 y 与自变量 $x_1, \dots, x_m$ 构成的回归模型称为全模型; 从 m 个自变量中选择 p 个自变量, 由因变量 y 与自变量 $x_1, \dots, x_p$ 构成的回归模型称为选模型.

2. 自变量选择对模型预测的影响:

(1) 全模型正确而误用选模型的情况:

①当 $(\beta_{p+1}^{(m)}, \dots, \beta_m^{(m)})' \neq 0$ 且 $(x_1, \dots, x_p)(x_{p+1}, \dots, x_m)'$ 时, 选模型的回归系数最小二乘估计是全模型对应回归系数的有偏估计, 即 $E\left((\hat{\beta}_1^{(p)}, \dots, \hat{\beta}_p^{(p)})'\right) \neq (\beta_1^{(m)}, \dots, \beta_p^{(m)})'$.

【例题 20】求证: 上述命题成立.

②当 $(\beta_{p+1}^{(m)}, \dots, \beta_m^{(m)})' \neq 0$ 时，选模型预测是全模型预测的有偏估计，即 $E(\hat{y}^{(p)}) \neq X\beta$.

【例题 21】求证：上述命题成立.

③选模型回归系数估计的方差比全模型对应回归系数估计的方差更小，即

$$D((\hat{\beta}_1^{(p)}, \dots, \hat{\beta}_p^{(p)})') \leq D((\hat{\beta}_1^{(m)}, \dots, \hat{\beta}_p^{(m)})')$$

【例题 22】求证：上述命题成立.

④选模型预测残差的方差比全模型对应预测残差的方差更小，即 $D(e^{(p)}) \leq D(e^{(m)})$.

【例题 23】求证：上述命题成立.

⑤当 $D((\beta_{p+1}^{(m)}, \dots, \beta_m^{(m)})') \geq (\beta_{p+1}^{(m)}, \dots, \beta_m^{(m)})'(\beta_{p+1}^{(m)}, \dots, \beta_m^{(m)})$ 时，选模型预测均方误差比全模型对应预测残差的方差更小，即 $E((e^{(p)})^2) \leq D(e^{(m)})$.

【例题 24】求证：上述命题成立.

(2) 选模型正确而误用全模型的情况：

- ①全模型预测是选模型对应预测的有偏估计；
- ②选模型的预测方差小于全模型的预测方差；
- ③全模型的预测误差更大.

3. 所有子集回归:

设研究问题所涉及的变量有 m 个, 则因变量 y 关于自变量所有可能回归方程共有 $2^m - 1$ 个.

4. 所有子集回归的自变量选择准则:

(1) 修正的复判定系数:

$$R_a^2(p) = 1 - \frac{n-1}{n-p-1}(1-R_p^2) = 1 - \frac{n-1}{n-p-1} \frac{SSE_p}{SST_p} = 1 - \frac{n-1}{SST_p} \hat{\sigma}_p^2$$

当 $R_a^2(p)$ 最大时, 所选择的自变量拟合的回归方程最优;

(2) AIC 准则:

$$AIC = n \ln SSE + 2p$$

当 AIC 最小时, 所选择的自变量拟合的回归方程最优;

(3) C_p 统计量:

$$C_p = \frac{SSE_p}{SSE_m/(n-m-1)} - n + 2p$$

当 C_p 最接近 p 时, 所选择的自变量拟合的回归方程最优;

(4) 预测平方和准则:

$$PRESS_p = \sum_{i=1}^n (y_i - \hat{y}_{(i)}^{(p)})^2 = \sum_{i=1}^n \left(\frac{e_i^{(p)}}{1 - h_{ii}^{(p)}} \right)^2$$

其中, $\hat{y}_{(i)}^{(p)}$ 为删除第 i 组观测值后利用其余 $n-1$ 组观测值拟合的回归方程的预测值.

当 $PRESS_p$ 最小时, 所选择的自变量拟合的回归方程最优.

【例题 25】根据构造公式简述各自变量选择准则的基本思想.

5. 前进法与后退法选择自变量:

(1) 前进法:

①将 m 个自变量分别对因变量 y 建立 $p = 1, \dots, m$ 元线性回归方程, 并计算 F 值 $\{F_1^{(p)}, \dots, F_m^{(p)}\}$;

②选择 $F_i^{(p)} = \max\{F_1^{(p)}, \dots, F_m^{(p)}\} \geq F_\alpha(1, n-p-1)$ 对应变量 x_i , 对剩下 $m-p$ 个变量重复①;

③当所有剩余变量的 F 值均小于 $F_\alpha(1, n-p-1)$ 为止, 得到的回归方程为最终确定的方程.

(2) 后退法: 前进法的逆过程

从 m 元线性回归方程检查 $F_i^{(p)} = \min\{F_1^{(p)}, \dots, F_m^{(p)}\} \leq F_\alpha(1, n-p-1)$ 对应变量 x_i 并剔除.

6. 逐步回归选择自变量:

在前进法的基础上, 每选择一个变量后对所有已选择的变量逐个检验, 当已选择变量由于后选择变量的而变得不再显著时, 将其剔除, 以确保新变量之前回归方程中只包含显著的变量. 反复进行直到既无显著的自变量选入回归方程, 也无不显著的自变量从回归方程中剔除, 弥补前进法和后退法各自的缺陷, 保证了最后所得的回归子集是最优回归子集.

*要求引入自变量时的显著性水平小于剔除自变量时的显著性水平.

五、违背基本假设的情况

1. 异常值: $E(\varepsilon_i) \neq 0$

(1) 判断异常值的方法:

①残差图:

②标准化残差与学生化残差:

$$|ZRE_i| = \left| \frac{e_i}{\hat{\sigma}} \right| > 3 \quad |SRE_i| = \left| \frac{e_i}{\hat{\sigma}\sqrt{1-h_{ii}}} \right| > 3, \text{ 其中 } H = X(X'X)^{-1}X'$$

③删除残差与学生化删除残差:

$$e_{(i)} = y_i - \hat{y}_{(i)} = \frac{e_i}{1-h_{ii}} \quad |SRE_{(i)}| = \left| SRE_i \sqrt{\frac{n-p-2}{n-p-1-SRE_i^2}} \right| > 3$$

④Cook 距离与强影响点:

$$D_i = \frac{e_i^2}{2\hat{\sigma}^2} \frac{h_{ii}}{(1-h_{ii})^2} > 1 \quad ch_{ii} = h_{ii} - \frac{1}{n} > 2\overline{ch} = \frac{2}{n}$$

(2) 判断异常值的产生情况及其对应方法:

①关于因变量 y 的异常值: 残差分析;

②关于自变量 x 的异常值: 强影响点.

2. 异方差: $D(\varepsilon_i) \neq D(\varepsilon_j)$

(1) 判断异方差的方法: 残差图.

(2) 消除异方差的方法:

①加权最小二乘估计 (WLSE):

$$\hat{\beta}_w = (X'WX)^{-1}X'Wy$$

其中, $W = \begin{bmatrix} w_1 & & \\ & \ddots & \\ & & w_n \end{bmatrix}$, 权函数取幂函数 x_i^m , x_i 为与残差等级相关系数最大的自变量.

②BOX-COX 幂变换族:

当 y 各分量均大于0时, 可作如下变换; 否则可以先对 y 进行平移变换, 再作如下变换:

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln y, & \lambda = 0 \end{cases}$$

其中, λ 的极大似然估计当 $SSE(\lambda, y^{(\lambda)})$ 取最小值时取得:

$$SSE(\lambda, z^{(\lambda)}) = z^{(\lambda)'}(E_n - X(X'X)^{-1}X')z^{(\lambda)}$$

$$\text{其中, } z_i^{(\lambda)} = \begin{cases} \frac{y_i^{(\lambda)}}{\left(\prod_{i=1}^n y_i\right)^{\frac{\lambda-1}{n}}}, & \lambda \neq 0 \\ (\ln y_i) \left(\prod_{i=1}^n y_i\right)^{\frac{1}{n}}, & \lambda = 0 \end{cases} . \text{ 当 } \lambda = 0 \text{ 时, BOX-COX 变换为对数变换.}$$

3. 自相关: $\text{cov}(\varepsilon_i, \varepsilon_j) \neq 0$

(1) 判断自相关的方法:

①残差图: 以因变量拟合值、自变量观测值、交叉项乘积、时间顺序为横坐标的残差图.

②自相关系数与 DW 检验.

(2) 消除自相关的方法:

①迭代法及差分法.

②BOX-COX 幂变换族.

4. 非正态分布: $\varepsilon_i \sim N(0, \sigma^2)$

(1) 判断非正态分布的方法:

①残差正态性频率检验:

将学生化残差落在范围内的频率与标准正态分布在相应范围内的概率作比较:

若差异大, 则认为残差不服从正态分布, 从而模型的误差项不服从正态分布假定.

②残差正态性 QQ 图检验:

求学生化残差的次序统计量 $SRE_{(i)}$, 并画散点图

$$\left(\Phi^{-1}\left(\frac{i - 0.375}{n + 0.25}\right), SRE_{(i)} \right), \quad \text{其中 } \Phi^{-1}(x) \text{ 为 } N(0,1) \text{ 分布函数的反函数}$$

若 $SRE_{(i)}$ 近似于正态分布, 则在 QQ 图上散点大致在一条直线上; 或利用相关系数检验.

(2) 消除非正态的方法: BOX-COX 幂变换族.

【例题 26】说明 BOX-COX 变换的使用条件以及优劣势.

六、多重共线性: $r(X) < p + 1$

1. 多重共线性产生的原因:

(1) 时间序列数据: 经济变量随时间变化而产生的共同变化趋势;

(2) 横截面数据: 数据因素之间存在强相关性.

2. 多重共线性对回归模型的影响:

(1) 回归系数参数估计结果方差 $D(\hat{\beta})$ 较大, 估计精度较低;

(2) 低估 t 值, 部分回归系数不能通过显著性检验;

(3) 回归系数无偏, 但不符合实际意义, 影响模型应用.

【例题 27】分别解释多重共线性对回归模型的影响.

3. 判断多重共线性的方法:

(1) 直观判定:

- ①增加或删除一个变量时, 其他自变量的回归系数的估计值或显著性发生较大变化;
- ②在自变量的相关矩阵中, 自变量间的相关系数较大;
- ③与因变量之间简单相关系数绝对值很大的自变量在回归方程中没有通过显著性检验;
- ④重要自变量在回归方程中没有通过显著性检验, 回归系数大小或符号与预期相差较大.

(2) 方差扩大因子:

对每一组数据的自变量做标准化, 并重新构成标准化设计矩阵:

$$X^* = \begin{bmatrix} 0 & \frac{x_{11} - \bar{x}_1}{\sqrt{L_{11}}} & \frac{x_{12} - \bar{x}_2}{\sqrt{L_{22}}} & \dots & \frac{x_{1p} - \bar{x}_p}{\sqrt{L_{pp}}} \\ 0 & \frac{x_{21} - \bar{x}_1}{\sqrt{L_{11}}} & \frac{x_{22} - \bar{x}_2}{\sqrt{L_{22}}} & \dots & \frac{x_{2p} - \bar{x}_p}{\sqrt{L_{pp}}} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \frac{x_{n1} - \bar{x}_1}{\sqrt{L_{11}}} & \frac{x_{n2} - \bar{x}_2}{\sqrt{L_{22}}} & \dots & \frac{x_{np} - \bar{x}_p}{\sqrt{L_{pp}}} \end{bmatrix} \quad \text{其中, } L_{jj} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2, \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

令 $C^* = (X^{*'} X^*)^{-1}$, 则其对角线元素 $VIF_j = c_{jj}^*$ 称为自变量 x_j 的方差扩大因子.

判定标准: 当 $VIF_j \geq 10$ 时, 认为变量 x_j 与其余变量之间存在强多重共线性.

【例题 28】求证: $D(\hat{\beta}_j) = c_{jj}^* \frac{\sigma^2}{L_{jj}}$, $c_{jj}^* = \frac{1}{1-R_j^2}$, 其中 R_j^2 为变量 x_j 与其余变量之间的复判定系数, 并据此指出方差扩大因子对于判定多重共线性的基本思想.

(3) 特征值分析:

当矩阵 $X'X$ 至少有一个特征值近似于 0 时, X 的列向量间存在多重共线性, 且特征值近似于 0 的个数即设计矩阵 X 中存在的多重共线性关系数.

【例题 29】推导特征值分析对于判定多重共线性的基本思想.

(4) 条件数:

$$\kappa_i = \frac{\sqrt{\lambda_{\max}}}{\sqrt{\lambda_i}} = \frac{\sigma_{\max}}{\sigma_i}$$

当 $\kappa_i > 10$ 时, 认为变量 x_i 与其余变量之间存在强多重共线性.

4. 初等消除多重共线性的方法:

- (1) 删除不必要的解释变量;
- (2) 增大样本容量, 保证 n 远大于 p ;
- (3) 使用惩罚回归: 岭回归、Lasso、弹性网模型;
- (4) 使用降维思想: 主成分回归、偏最小二乘回归.

5. 岭回归:

(1) 岭回归的定义:

$$\hat{\beta}(k) = (X^{*'}X^* + kE_{p+1})^{-1}X^{*'}y$$

其中, X^* 为对原始数据的标准化数据, $x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{\sqrt{L_{jj}}}$.

(2) 岭回归估计的性质:

① $\hat{\beta}(k)$ 为 β 的有偏估计;


【例题 30】求证: $\hat{\beta}(k)$ 为 β 的有偏估计.

② $MSE(\hat{\beta}(k)) < MSE(\hat{\beta})$.


【例题 31】求证: $MSE(\hat{\beta}(k)) < MSE(\hat{\beta})$.

(3) 岭迹分析:

- a. $\hat{\beta}_j(k)$ 图形不稳定, x_j 对 y 没有重要影响作用;
- b. $\hat{\beta}_j(k)$ 图形不稳定, x_j 对 y 有重要影响作用;
- c. $\hat{\beta}_j(k)$ 图形稳定, x_j 对 y 有负影响作用;
- d. $\hat{\beta}_i(k) + \hat{\beta}_j(k)$ 图形稳定, x_i 与 x_j 存在多重共线性;




- e. 所有回归系数的岭迹不稳定, 最小二乘估计效果较差;
- f. 所有回归系数的岭迹稳定, 最小二乘估计效果较好.



(4) 参数 k 的选择:

①岭迹法直观选择:

- 各回归系数的岭估计基本稳定;
- 岭估计的符号变得合理;
- 回归系数没有不合乎经济意义的绝对值;
- 残差平方和增加不太多.



②方差扩大因子:

$$D(\hat{\beta}(k)) = \sigma^2 \left((X^{*'}X^* + kE_{p+1})^{-1} X^{*'}X^* (X^{*'}X^* + kE_{p+1})^{-1} \right)$$

$C(k) = (X^{*'}X^* + kE_{p+1})^{-1} X^{*'}X^* (X^{*'}X^* + kE_{p+1})^{-1}$ 的主对角线元素为方差扩大因子 $C_{jj}(k)$, $C_{jj}(k)$ 随 k 的增大而减少, 当 $C_{jj}(k) \leq 10$ 时, 岭估计 $\hat{\beta}(k)$ 相对稳定.

6. 惩罚回归的一般形式:

$$\hat{\beta}(\lambda) = \operatorname{argmin} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda P(\beta) \right\}$$

其中, $\lambda P(\beta)$ 为罚项, λ 为罚参数, $P(\beta)$ 为具体的罚函数, 可由不同形式确定:

(1) Lasso: $P(\beta)$ 采用 L-1 范数

$$\hat{\beta}(\lambda) = \operatorname{argmin} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

(2) 岭回归: $P(\beta)$ 采用 L-2 范数


$$\hat{\beta}(\lambda) = \operatorname{argmin} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}$$

(3) 弹性网模型: Lasso 与岭回归结合

$$\hat{\beta}(\lambda) = \operatorname{argmin} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \left(\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right) \right\}$$

Lasso 的最优解是一个菱形区域, 而岭回归的最优解是一个圆形区域, 因此:

岭回归一般不能使得系数完全压缩为0, 而是使其接近于0; Lasso 可以使得系数为零.



7. 主成分回归 (PCR):

利用主成分之间互不相关的性质, 可以通过依据解释变量的方差贡献率选择主成分来代替原来的解释变量, 从而达到降维的目的, 解决多重共线性问题.

8. 偏最小二乘估计 (PLSE):

(1) Wold 算法:

① 中心化 X, y :

$$x'_i = x_i - \bar{x}_i, \quad y' = y - \bar{y}$$

② 初始化 $y_0 = y', X_0 = X', \hat{y}_0 = 0, \hat{X}_0 = 0$;

③ 循环 $k = 1, \dots, r$:

$$t_k = X_{k-1}' X_{k-1}' y_{k-1};$$

$$\hat{y}_k = \frac{t_k t_k'}{t_k' t_k} y_{k-1} + \hat{y}_{k-1};$$

$$y_k = y_{k-1} - \frac{t_k t_k'}{t_k' t_k} y_{k-1};$$

$$\hat{X}_k = \frac{t_k t_k'}{t_k' t_k} X_{k-1};$$

$$X_k = X_{k-1} - \hat{X}_k;$$

④ 如果 $X_k X_k'$ 中主对角元素近似为 0, 结束循环.

(2) Helland 算法:

① 中心化 X, y :

$$x'_i = x_i - \bar{x}_i, \quad y' = y - \bar{y}$$

② 初始化 $y_0 = y', X_0 = X'$;

③ 循环 $k = 1, \dots, r$:

$$t_k = (X' X)^{k-1} X' y;$$

用 y' 对 $X_{t_1}, \dots, X_{t_k}$ 做普通最小二乘回归, 得到 $\hat{y}_k$;

④ 选择合适的 $\hat{y}_k$, 结束循环.

(3) 交叉验证法:

从样本 X, y 中删去第 i 组资料, 用 $X(-i), Y(-i)$ 表示, 用 PLS 方法计算出 $X(-i), Y(-i)$ 的预测方程中 $\hat{y}_{ki}(-i)$ 的表达式, 然后将 x_i 代入计算出预测值 $\hat{y}_{ki}(-i)$, 则残差 $y_i - \hat{y}_{ki}(-i)$ 反映了

第 k 步预测方程在第 i 组样本的效果, 残差平方和作为损失 $L(k) = \sum_{i=1}^n (y_i - \hat{y}_{ki}(-i))^2$ 在整体

上反映了第 k 步预测方程的效果, 只需求 $L(k^*) = \min_{1 \leq k \leq r} L(k)$ 即可.

9. 主成分回归 (PCR) 与偏最小二乘估计 (PLSE) 对样本数量少于解释变量个数的处理:

当 $n < p$ 时, 矩阵 $X'X$ 为奇异矩阵, 无法求逆, 进而不能用普通最小二乘进行估计.

(1) 主成分回归 (PCR) 直接求 $X'X$ 的特征值, 按大小顺序排列 $\lambda_1 \geq \dots \geq \lambda_r > 0$, 相应的特征向量分别记为 $u_1, \dots, u_r$, 令 $Y = U'X$, 则 $Y_1, \dots, Y_r$ 都是 $X_1, \dots, X_n$ 的线性函数, 从而只需要对 $Y_1, \dots, Y_r$ 部分进行回归, 解决了 $n < p$ 的问题, 但选择 $Y_1, \dots, Y_r$ 的方法与因变量 y 无关;

(2) 偏最小二乘 (PLSE) 考虑与 y 的相关性, 算法基于最小二乘, 但只选与 y 有相关性的变量而不考虑全部 $X_1, \dots, X_n$ 的线性函数.

第4章 非线性回归与定性变量回归

一、曲线回归

1. 若对回归模型自变量或因变量做函数变换后转化为线性模型，则称该模型为可化为线性回归的曲线回归模型，其中新引入的自变量智能依赖于原始变量而不能与未知参数有关。

【例题 1】将下列非线性回归模型做适当的变换，转化为线性回归模型：

(1) $y = \beta_0 + \beta_1 e^{bx} + \varepsilon$ ，其中 b 为已知参数；

(2) $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_p x^p + \varepsilon$ ；

(3) $y = ae^{bx} e^{\varepsilon}$ ；

(4) $y = \beta_0 + \frac{\beta_1}{x}$ ， $y = e^{\beta_0 + \frac{\beta_1}{x}}$ ；

(5) $y = \beta_0 x^{\beta_1}$ ；

(6) $y = \beta_0 \beta_1^x$ ， $y = e^{\beta_0 + \beta_1 x}$ ， $y = \beta_0 e^{\beta_1 x}$ ；

(7) $y = \frac{1}{\frac{1}{b} + \beta_0 \beta_1^x}$ ，其中 b 为已知参数。

2. 非线性模型是否可以线性化的因素包括回归函数的形式、误差项的形式。

3. 多项式回归模型： $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_p x^p + \varepsilon$

(1) 一元二次多项式回归模型： $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \varepsilon_i$ ；

(2) 一元三次多项式回归模型： $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \varepsilon_i$ ；

(3) 二元二次多项式回归模型： $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_{11} x_{i1}^2 + \beta_{22} x_{i2}^2 + \beta_{12} x_{i1} x_{i2} + \varepsilon_i$ 。

4. 非线性最小二乘法：

设非线性回归模型 $y_i = f(x_i; \theta) + \varepsilon_i$ ，离差平方和（平方损失函数）：

$$Q(\theta) = \sum_{i=1}^n (y_i - f(x_i; \theta))^2$$

对参数 θ_i 求偏导数，即可得到非线性方程组，从而求得非线性最小二乘估计值。

5. 绝对值损失函数：（具有更强的稳健性）

$$Q(\theta) = \sum_{i=1}^n |y_i - f(x_i; \theta)|$$

二、自变量含定性变量的回归模型

1. 定性变量为0-1型变量:

设在一般情况下, 线性回归模型为 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, 对于虚拟变量

$$D_i = \begin{cases} 1, & \text{某种情况} \\ 0, & \text{else} \end{cases}$$

(1) 仅影响截距项:

$$y_i = \beta_0 + \beta_1 x_i + \alpha D_i + \varepsilon_i = \begin{cases} \beta_0 + \alpha + \beta_1 x_i + \varepsilon_i, & \text{某种情况} \\ \beta_0 + \beta_1 x_i + \varepsilon_i, & \text{else} \end{cases}$$

(2) 仅影响斜率项:

$$y_i = \beta_0 + \beta_1 x_i + \alpha D_i x_i + \varepsilon_i = \begin{cases} \beta_0 + (\beta_1 + \alpha) x_i + \varepsilon_i, & \text{某种情况} \\ \beta_0 + \beta_1 x_i + \varepsilon_i, & \text{else} \end{cases}$$

(3) 同时影响截距项和斜率项:

$$y_i = \beta_0 + \beta_1 x_i + \alpha_0 D_i + \alpha_1 D_i x_i + \varepsilon_i = \begin{cases} \beta_0 \alpha_0 + (\beta_1 + \alpha_1) x_i + \varepsilon_i, & \text{某种情况} \\ \beta_0 + \beta_1 x_i + \varepsilon_i, & \text{else} \end{cases}$$

2. 定性变量为多类值:

对定性变量有 k 种状态, 应设置 $k-1$ 个0-1型虚拟变量, 否则会构成完全多重共线性.

$$D_{ij} = \begin{cases} 1, & \text{第}i\text{种情况} \\ 0, & \text{else} \end{cases}$$

3. 分段回归:

利用0-1型变量, 可对回归模型做分段回归处理:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 (x_i - c_0) D_i + \varepsilon_i$$

其中, $D_i = \begin{cases} 1, & x_i > c_0 \\ 0, & x_i \leq c_0 \end{cases}$, 则该线性回归模型在 c_0 处被分为两段不同的线性回归模型.

三、因变量含定性变量的回归模型

1. 定性变量为0-1型变量:

设在一般情况下, 线性回归模型为 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, 则 y 的取值只有0,1:

$$P(y_i = 1) = p, \quad P(y_i = 0) = 1 - p$$

则 $y_i \sim B(1, p)$, 从而 $E(y_i) = \beta_0 + \beta_1 x_i = p$.

2. 定性变量回归的特殊情况:

(1) 误差项为离散非正态;

(2) 误差项异方差: $D(\varepsilon_i) = (\beta_0 + \beta_1 x_i)(1 - \beta_0 - \beta_1 x_i)$;

(3) 回归方程的限制: $0 \leq E(y_i) \leq 1$.

3. Logistic 回归模型:

$$f(x_i) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip})}}$$

作 logit 变换:

$$g(x_i) = \ln \left(\frac{f(x_i)}{1 - f(x_i)} \right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}$$

4. 最大似然估计法求 Logistic 回归模型:

设 $y_i \sim B(1, f(x_i))$, 即 $P(y_i = 1) = f(x_i)$, $P(y_i = 0) = 1 - f(x_i)$, 则概率密度函数

$$P(y_i) = f(x_i)^{y_i} (1 - f(x_i))^{1-y_i}$$

则似然函数

$$L(y_i, f(x_i)) = \prod_{i=1}^n f(x_i)^{y_i} (1 - f(x_i))^{1-y_i}$$

取对数, 有

$$\begin{aligned} l(y_i, f(x_i)) &= \sum_{i=1}^n \left(y_i \ln \frac{f(x_i)}{1 - f(x_i)} + \ln(1 - f(x_i)) \right) \\ &= \sum_{i=1}^n (y_i (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}) - \ln(1 + e^{\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}})) \end{aligned}$$

5. Probit 回归模型:

$$\Phi^{-1}(f(x_i)) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}$$

【例题 2】简要说明含定性变量的回归分析.

第 5 章 多元正态分布

一、随机向量及其性质

1. n 个 p 维的随机向量数据矩阵:

$$X = \begin{bmatrix} & \text{维度 1} & \text{维度 2} & \cdots & \text{维度 } p \\ \text{样本 1} & x_{11} & x_{12} & \cdots & x_{1p} \\ \text{样本 2} & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ \text{样本 } n & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

2. 联合分布函数与联合概率密度函数的定义:

设 p 维随机向量 $X = (X_1, X_2, \dots, X_p)'$, 其分布函数为

$$F(x_1, \dots, x_p) = P(X_1 \leq x_1, \dots, X_p \leq x_p) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_p} f(x_1, \dots, x_p) dx_p \cdots dx_1$$

其中, 联合概率密度函数满足非负性、规范性:

$$\begin{cases} f(x_1, \dots, x_p) \geq 0 \\ \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(x_1, \dots, x_p) dx_p \cdots dx_1 = 1 \end{cases}$$

【例题 1】设 $X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix}$ r 维, $p-r$ 维, 求 $X^{(1)}$ 的边缘分布函数与边缘概率密度函数.

【例题 2】设 $X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$, $f(x_1, x_2) = \frac{1}{2\pi} e^{-\frac{1}{2}(x_1^2 + x_2^2)} (1 + x_1 x_2 e^{-\frac{1}{2}(x_1^2 + x_2^2)})$, 求 X_1, X_2 的边缘分布.

3. 条件分布函数与条件概率密度函数的定义:

设 $X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix}$ r 维, $p-r$ 维, X 的概率密度函数为 $f(x^{(1)}, x^{(2)})$, 则在 $X^{(2)} = x^{(2)}$ 的条件下 $X^{(1)}$ 的条件

概率密度函数为 $f_1(x^{(1)} | x^{(2)}) = \frac{f(x^{(1)}, x^{(2)})}{f_2(x^{(2)})}$.

4. 独立性的定义:

$$\begin{aligned} F(x_1, \dots, x_p) &= F_1(x_1) \cdots F_p(x_p) \\ f(x_1, \dots, x_p) &= f_1(x_1) \cdots f_p(x_p) \end{aligned}$$

5. 随机向量的数字特征:

(1) 均值向量:

$$E(X) = \begin{bmatrix} E(X_1) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_p \end{bmatrix}$$

均值向量具有如下性质:

$$E(AX) = A E(X), \quad E(AXB) = A E(X) B$$

(2) 方差矩阵:

$$D(X) = \begin{bmatrix} D(X_1) & \text{cov}(X_1, X_2) & \cdots & \text{cov}(X_1, X_p) \\ \text{cov}(X_2, X_1) & D(X_2) & \cdots & \text{cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_p, X_1) & \text{cov}(X_p, X_2) & \cdots & D(X_p) \end{bmatrix}$$

方差矩阵具有如下性质:

$$D(AX) = A D(X) A'$$

(3) 协方差矩阵:

$$\text{cov}(X, Y) = \begin{bmatrix} \text{cov}(X_1, Y_1) & \text{cov}(X_1, Y_2) & \cdots & \text{cov}(X_1, Y_q) \\ \text{cov}(X_2, Y_1) & \text{cov}(X_2, Y_2) & \cdots & \text{cov}(X_2, Y_q) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_p, Y_1) & \text{cov}(X_p, Y_2) & \cdots & \text{cov}(X_p, Y_q) \end{bmatrix}$$

协方差矩阵具有如下性质:

$$\text{cov}(AX, BY) = A \text{cov}(X, Y) B'$$

$$X, Y \text{ 相互独立} \Leftrightarrow \text{cov}(X, Y) = 0$$

(4) 相关矩阵:

$$R(X) = \begin{bmatrix} 1 & r(X_1, X_2) & \cdots & r(X_1, X_p) \\ r(X_2, X_1) & 1 & \cdots & r(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ r(X_p, X_1) & r(X_p, X_2) & \cdots & 1 \end{bmatrix}$$

相关矩阵可由方差矩阵和标准差矩阵求得:

$$D(X) = \begin{bmatrix} \sigma(X_1) & & \\ & \ddots & \\ & & \sigma(X_p) \end{bmatrix} R(X) \begin{bmatrix} \sigma(X_1) & & \\ & \ddots & \\ & & \sigma(X_p) \end{bmatrix}$$

(5) 方差矩阵分解定理:

$$D(X) = \Sigma = L^2$$

【例题 3】求证: 方差矩阵可分解 $\Sigma = L^2$.

二、多元正态分布

1. 多元正态分布的定义 1（推广定义）：

若 p 维随机向量 X 的任意线性组合均服从一元正态分布，则 X 为 p 维正态随机向量。

2. 多元正态分布的定义 2（构造定义）：

设 $X = (X_1, X_2, \dots, X_q)'$ 为随机向量， $X_1, X_2, \dots, X_q$ 独立同分布 $N(0,1)$ ， μ 为 p 维向量， A 为 $p \times q$ 矩阵，则 $Y = AX + \mu$ 服从 p 维正态分布，记作 $Y \sim N_p(\mu, AA')$ 。

3. 多元正态分布的定义 3（特征函数）：

若随机向量 X 的特征函数满足

$$\Phi_X(t) = e^{it'\mu - \frac{1}{2}t'\Sigma t}, \quad \Sigma \geq 0$$

则 $X \sim N_p(\mu, \Sigma)$ 。

4. 多元正态分布的定义 4（概率密度）：

若 p 维随机向量 $X = (X_1, X_2, \dots, X_p)'$ 的联合概率密度函数为

$$f(x) = \frac{1}{(\sqrt{2\pi})^p \sqrt{|\Sigma|}} e^{-\frac{1}{2}(x-\mu)'\Sigma^{-1}(x-\mu)}$$

则 $X \sim N_p(\mu, \Sigma)$ 。

5. 多元正态分布的性质：

（1）线性性质：

设 $X \sim N_p(\mu, \Sigma)$ ， A 为 $s \times p$ 矩阵， b 为 s 维向量，则 $Y = AX + b \sim N_s(A\mu + b, A\Sigma A')$ 。

【例题 4】求证：多元正态分布的线性性质。

（2）分块性质：

设 $X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix} \begin{matrix} r\text{维} \\ p-r\text{维} \end{matrix} \sim N_p(\mu, \Sigma)$ ， $\mu = \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix} \begin{matrix} r\text{维} \\ p-r\text{维} \end{matrix}$ ， $\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \begin{matrix} r\text{维} & p-r\text{维} \\ p-r\text{维} & \end{matrix}$ ，则

$$X^{(1)} \sim N_r(\mu^{(1)}, \Sigma_{11}), \quad X^{(2)} \sim N_{p-r}(\mu^{(2)}, \Sigma_{22})$$

6. 多元正态分布的独立性：

设 $X \sim N_p(\mu, \Sigma)$ ，则 $X^{(1)}, \dots, X^{(k)}$ 相互独立 $\Leftrightarrow \Sigma_{ij} = 0, \forall i \neq j$ ，即 $D(X) = \Sigma$ 为准对角矩阵。

7. 多元正态分布的条件分布：

$$\begin{aligned} (X^{(1)}|X^{(2)}) &\sim N_r(\mu^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(X^{(2)} - \mu^{(2)}), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}) \\ (X^{(2)}|X^{(1)}) &\sim N_{p-r}(\mu^{(2)} + \Sigma_{21}\Sigma_{11}^{-1}(X^{(1)} - \mu^{(1)}), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}) \end{aligned}$$

【例 5】根据条件分布说明 $X^{(2)}$ 与 $X^{(1)} - \Sigma_{12}\Sigma_{22}^{-1}X^{(2)}$ 之间的独立性、 $X^{(1)}$ 与 $X^{(2)} - \Sigma_{21}\Sigma_{11}^{-1}X^{(1)}$ 之间的独立性，并条件对方差的影响。

8. 条件期望：

$$(X^{(1)}|X^{(2)}) \sim N_r(\mu^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(X^{(2)} - \mu^{(2)}), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})$$

其中， $E(X^{(1)}|X^{(2)}) = \mu^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(X^{(2)} - \mu^{(2)})$ 称为条件期望， $\Sigma_{12}\Sigma_{22}^{-1}$ 为回归系数。

(1) 条件期望的线性性质：

$$E(C_0 + C_1Y_1 + \cdots + C_nY_n|X) = C_0 + C_1E(Y_1|X) + \cdots + C_nE(Y_n|X)$$

(2) 条件期望的乘积：

$$E(g(x)h(Y)|X) = g(x)E(h(Y)|X)$$

(3) 条件期望的重期望：

$$E(E(h(Y)|X = x)) = E(h(Y))$$

【例 6】求证：条件期望的重期望公式 $E(E(h(Y)|X = x)) = E(h(Y))$ 。

9. 最佳预测函数：对于 $X = \begin{bmatrix} Y \\ X^{(2)} \end{bmatrix}$ $\begin{matrix} 1 \text{ 维} \\ p-1 \text{ 维} \end{matrix}$ ，有 $E((Y - E(Y|X^{(2)}))^2) \leq E((Y - g(X^{(2)}))^2)$ 。

三、多元正态分布的参数估计

1. 样本离差矩阵：

$$L = \sum_{\alpha=1}^n (X_{(\alpha)} - \bar{X})(X_{(\alpha)} - \bar{X})' = X'X - n\bar{X}\bar{X}' = \tilde{X}'\tilde{X}$$

$$\text{其中，} \tilde{X} = \begin{bmatrix} (X_{(1)} - \bar{X})' \\ \vdots \\ (X_{(n)} - \bar{X})' \end{bmatrix}.$$

$$L_{ij} = \sum_{\alpha=1}^n (x_{\alpha i} - \bar{x}_i)(x_{\alpha j} - \bar{x}_j)$$

2. 样本协方差矩阵：

$$S = \frac{1}{n-1}L$$

其中，样本方差为

$$S_{ii} = \sum_{\alpha=1}^n (x_{\alpha i} - \bar{x}_i)^2$$

3. 多元正态分布的参数最大似然估计:

$$\hat{\mu} = \bar{X}, \quad \hat{\Sigma} = \frac{1}{n}L$$

【例题 7】求多元正态分布的数 $\hat{\mu}, \hat{\Sigma}$ 的最大似然估计.

4. 最大似然估计中统计量的性质:

设 p 维正态总体 $N_p(\mu, \Sigma)$ 的一组样本均值向量为 $\bar{X}$, 样本离差矩阵为 L , 则

$$(1) \bar{X} \sim N_p\left(\mu, \frac{1}{n}\Sigma\right); (2) L = \sum_{i=1}^{n-1} Z_i Z_i', \text{ 其中 } Z_i \stackrel{i.i.d.}{\sim} N_p(0, \Sigma); (3) \bar{X} \text{ 与 } L \text{ 相互独立.}$$

【例题 8】求证: 上述命题成立.

5. 最大似然估计量的性质:

(1) 无偏性: $E(\bar{X}) = \mu$, 无偏; $E(L) = (n-1)\Sigma$, 有偏; $E(S) = \Sigma$, 无偏;

(2) 有效性: $\hat{\mu} = \bar{X}$, $\hat{\Sigma} = S$ 均为有效估计量, 是最小方差无偏估计;

(3) 相合性: $\hat{\mu} = \bar{X}$, $\hat{\Sigma} = \frac{1}{n}L$ 分别为当 $n \rightarrow \infty$ 时 μ, Σ 的强相合估计;

(4) 充分统计量: $\hat{\mu} = \bar{X}$, $\hat{\Sigma} = \frac{1}{n}L$ 分别为 μ, Σ 的充分统计量.

6. 参数函数的最大似然估计:

设 p 维正态总体 $N_p(\mu, \Sigma)$, $\hat{\mu} = \bar{X}$, $\hat{\Sigma} = \frac{1}{n}L$, 则 $g(\mu, \Sigma)$ 的最大似然估计为 $\hat{g}(\bar{X}, \frac{1}{n}L)$.

四、多元正态分布的假设检验

1. 多元抽样分布:

(1) 正态变量二次型的分布:

设 $X_i \sim N(0, \sigma^2)$ 是相互独立的随机变量, 则

$$\frac{1}{\sigma^2} X'X = \frac{1}{\sigma^2} \sum_{i=1}^n X_i^2 \sim \chi^2(n)$$

① 非中心 χ^2 分布:

设 n 维随机向量 $X \sim N_n(\mu, E_n)$, $X'X$ 自由度为 n , 非中心参数为 $\mu'\mu$, 记作

$$X'X \sim \chi^2(n, \mu'\mu)$$

② 非中心 t 分布:

设随机变量 $X \sim N(\delta, 1)$ 与 $Y \sim \chi^2(n)$ 相互独立, $\frac{X}{\sqrt{Y/n}}$ 自由度为 n , 非中心参数为 δ , 记作

$$\frac{X}{\sqrt{Y/n}} \sim t(n, \delta)$$

③ 非中心 F 分布:

设随机变量 $X \sim \chi^2(m, \delta)$ 与 $Y \sim \chi^2(n)$ 相互独立, $\frac{X/m}{Y/n}$ 自由度为 m, n , 非中心参数为 δ , 记作

$$\frac{X/m}{Y/n} \sim F(m, n, \delta)$$

【例题 9】求证: 设 $X \sim N_p(\mu, \Sigma)$, $\Sigma > 0$, 则 $X'\Sigma^{-1}X \sim \chi^2(p, \mu'\Sigma^{-1}\mu)$.

(2) Wishart 分布:

设 $X_{(i)} \sim N_p(0, \Sigma)$ 相互独立, $i = 1, \dots, n$, $X = \begin{bmatrix} X_{(1)} \\ \vdots \\ X_{(n)} \end{bmatrix}$, 则

$$W = X'X \sim W_p(n, \Sigma)$$

① 设 $X_{(i)} \sim N_p(\mu, \Sigma)$ 相互独立, $i = 1, \dots, n$, 样本离差矩阵

$$L = \sum_{\alpha=1}^n (X_{(\alpha)} - \bar{X})(X_{(\alpha)} - \bar{X})' \sim W_p(n-1, \Sigma)$$

② Wishart 分布的可加性: 设 $W_i \sim W_p(n_i, \Sigma)$, 则

$$W_1 + \dots + W_k \sim W_p(n_1 + \dots + n_k, \Sigma)$$

③ 设 $W \sim W_p(n, \Sigma)$, C 为 $m \times p$ 常数矩阵, 则

$$CWC' \sim W_m(n, C\Sigma C')$$

④ 设 $W \sim W_p(n, \Sigma)$, 则 $E(W) = n\Sigma$.

(3) Hotelling T^2 分布:

设总体 $X \sim N_p(0, \Sigma)$, $W \sim W_p(n, \Sigma)$, $\Sigma > 0$, $n \geq p$, X 与 W 相互独立, 则

$$T^2 = X' \left(\frac{1}{n} W \right)^{-1} X \sim T^2(p, n)$$

① 设 $X_{(i)} \sim N_p(\mu, \Sigma)$ 相互独立, $i = 1, \dots, n$, 样本离差矩阵 L , 样本均值向量 $\bar{X}$, 则

$$\left(\sqrt{n}(\bar{X} - \mu) \right)' \left(\frac{1}{n-1} L \right)^{-1} \left(\sqrt{n}(\bar{X} - \mu) \right) \sim T^2(p, n-1)$$

② 设 $T^2 \sim T^2(p, n)$, 则

$$\frac{n-p+1}{np} T^2 \sim F(p, n-p+1)$$

(4) Wilks Λ 分布:

设 $L_1 \sim W_p(n_1, \Sigma)$, $L_2 \sim W_p(n_2, \Sigma)$, L_1, L_2 相互独立, 则

$$\Lambda = \frac{|L_1|}{|L_1 + L_2|} \sim \Lambda(p, n_1, n_2)$$

① 当 $n_2 = 1$ 时, 设 $n_1 > p$, 则

$$\frac{n_1 - p + 1}{n_1 p} T^2 = \frac{n_1 - p + 1}{p} \frac{1 - \Lambda}{\Lambda} \sim F(p, n - p + 1)$$

② 若 $\Lambda(p, n_1, n_2)$, 则存在 $B_k \sim B\left(\frac{n_1 - p + k}{2}, \frac{n_2}{2}\right)$ 相互独立, $k = 1, \dots, p$, 使得

$$\Lambda = B_1 \dots B_p$$

③ 若 $n_2 < p$, 则

$$\Lambda(p, n_1, n_2) = \Lambda(n_2, p, n_1 + n_2 - p)$$

2. 均值向量的检验:

检验类型	检验情形	检验统计量
单正态总体均值向量检验	$\Sigma = \Sigma_0$ 已知	$T_0^2 = n(\bar{X} - \mu_0)' \Sigma_0^{-1} (\bar{X} - \mu_0) \sim \chi^2(p)$
	Σ 未知	$T^2 = n(\bar{X} - \mu_0)' \left(\frac{1}{n-1} A \right)^{-1} (\bar{X} - \mu_0) \sim T^2(p, n-1)$ $F = \frac{(n-1) - p + 1}{(n-1)p} T^2 \sim F(p, n-p)$
两正态总体均值向量检验	两总体协方差阵未知但相等	$T^2 = \frac{nm}{n+m} (\bar{X} - \bar{Y})' \left(\frac{A_1 + A_2}{n+m-2} \right)^{-1} (\bar{X} - \bar{Y}) \sim T^2(p, n+m-2)$ 其中 $\begin{cases} A_1 = \sum_{\alpha=1}^n (X_{(\alpha)} - \bar{X})(X_{(\alpha)} - \bar{X})' \sim W_p(n-1, \Sigma) \\ A_2 = \sum_{\alpha=1}^m (Y_{(\alpha)} - \bar{Y})(Y_{(\alpha)} - \bar{Y})' \sim W_p(m-1, \Sigma) \end{cases}$ $F = \frac{(n+m-2) - p + 1}{(n+m-2)p} T^2 \sim F(p, n+m-p-1)$
	两总体协方差阵不等 (样本量 $n = m$)	构造成对数据 $Z_{(i)} = X_{(i)} - Y_{(i)}$, 进行单总体检验
	两总体协方差阵不等 (样本量 $n \neq m$ 但相差不大, 假设 $n < m$)	构造 $Z_{(i)} = X_{(i)} - \sqrt{\frac{n}{m}} Y_{(i)} + \frac{1}{\sqrt{nm}} \sum_{j=1}^n Y_{(j)} - \frac{1}{m} \sum_{j=1}^m Y_{(j)}$ ($i = 1, 2, \dots, n$), 进行单总体检验
	两总体协方差阵不等 (样本量 $n \neq m$ 且相差较大)	可构造近似检验统计量进行检验

3. 协方差矩阵的检验:

检验类型	检验情形	检验统计量
单个 p 元正态总体协方差阵的检验	$\Sigma = I_p$ 时 检验 $H_0 : \Sigma = I_p$ vs. $H_1 : \Sigma \neq I_p$	构造似然比统计量 $\lambda_1 = \exp \left\{ -\frac{1}{2} \text{tr}(A) \right\} A ^{n/2} \left(\frac{e}{n} \right)^{np/2}$ n 较大且原假设成立时, $-2 \ln \lambda_1$ 近似服从 $\chi^2 \left(\frac{p(p+1)}{2} \right)$
	$\Sigma \neq I_p$ 检验 $H_0 : \Sigma = \Sigma_0$ vs. $H_1 : \Sigma \neq \Sigma_0$	构造 $Y_{(\alpha)} = DX_{(\alpha)} \sim N_p(D\mu, D\Sigma D^T) = N_p(\mu^*, \Sigma^*)(\alpha = 1, 2, \dots, n)$, 其中 $D_{p \times p}$ 为非退化矩阵且 $D\Sigma_0 D^T = I_p$, 可从新样本出发作 $\Sigma^* = I_p$ 的检验 $\lambda_2 = \exp \left\{ -\frac{1}{2} \text{tr}(A^*) \right\} A^* ^{n/2} \left(\frac{e}{n} \right)^{np/2}$, $A = DAD^T$ $-2 \ln \lambda_2$ 近似服从 $\chi^2 \left(\frac{p(p+1)}{2} \right)$
	检验 $H_0 : \Sigma = \sigma^2 \Sigma_0$ (σ^2 未知)	构造似然比统计量 $\lambda_3 = \frac{ \Sigma_0^{-1} A ^{n/2}}{[tr(\Sigma_0^{-1} A/p)^{np/2}]}$, $W = (\lambda_3)^{2/n}$ 样本量 n 很大时, $-\left((n-1) - \frac{2p^2 + p + 2}{6p} \right) \ln W$ 近似服从 $\chi^2 \left(\frac{p(p+1)}{2} - 1 \right)$
		【注】 $\Sigma_0 = I_p$ 时, 该检验称为球度检验

第6章 判别分析与聚类分析

一、判别分析的基本思想

1. 判别分析的适用问题：被解释变量是属性变量，解释变量是度量变量。

2. 判别分析的基本要求：

- (1) 分组类型在两组以上；
- (2) 每组数据的规模至少在一个以上；
- (3) 解释变量是可测量的。

3. 判别分析的基本假设：

- (1) 每个解释变量不能是其他变量的线性组合，即不是多重共线性的；
- (2) 各组变量的协方差矩阵相等，便于采用线性判别函数；
- (3) 各个解释变量服从多元正态分布。

二、距离判别

1. 距离判别的定义：

设总体 G_i 的 n 个 p 维样本 $X_{n_i} = (x_{n_i1}, \dots, x_{n_ip})'$ ，总体 G_i 的均值向量估计量为 $\bar{X}_i = (\bar{x}_1, \dots, \bar{x}_p)'$ ，

总体 G_i 的协方差矩阵的估计量为 $S_i = \frac{1}{n-1}L_i = \frac{1}{n-1} \sum_{n_i=1}^n (X_{n_i} - \bar{X}_i)(X_{n_i} - \bar{X}_i)'$ ，

则该样本 X_{n_i} 对于总体 G_i 的距离为 $d^2(X_{n_i}, G_i) = (X_{n_i} - \bar{X}_i)' S_i^{-1} (X_{n_i} - \bar{X}_i)$

2. 两个总体的距离判别：设有两个总体 G_1, G_2 ，则样本 X 距离总体 G_2 与 G_1 之差为

$$d^2(X, G_2) - d^2(X, G_1) = (X - \bar{X}_2)' S_2^{-1} (X - \bar{X}_2) - (X - \bar{X}_1)' S_1^{-1} (X - \bar{X}_1)$$

(1) 当 $\Sigma_1 = \Sigma_2$ （或估计量 $S_1 = S_2$ ）时：

$$d^2(X, G_2) - d^2(X, G_1) = 2 \left(X - \frac{\bar{X}_1 + \bar{X}_2}{2} \right)' S^{-1} (\bar{X}_1 - \bar{X}_2)$$

其中， $S = \frac{1}{n_1+n_2-2} (L_1 + L_2)$ 。

记判别函数 $W(X) = \left(X - \frac{\bar{X}_1 + \bar{X}_2}{2} \right)' S^{-1} (\bar{X}_1 - \bar{X}_2) = \alpha' \left(X - \frac{\bar{X}_1 + \bar{X}_2}{2} \right)$ ，此时为线性判别函数，

判别准则：

$$\begin{cases} X \in G_1, & W(X) > 0 \\ X \in G_2, & W(X) < 0 \\ \text{待判}, & W(X) = 0 \end{cases}$$

(2) 当 $\Sigma_1 \neq \Sigma_2$ （或估计量 $S_1 \neq S_2$ ）时：

$$d^2(X, G_2) - d^2(X, G_1) = (X - \bar{X}_2)' S_2^{-1} (X - \bar{X}_2) - (X - \bar{X}_1)' S_1^{-1} (X - \bar{X}_1)$$

记判别函数 $W(X) = (X - \bar{X}_2)' S_2^{-1} (X - \bar{X}_2) - (X - \bar{X}_1)' S_1^{-1} (X - \bar{X}_1)$ ，此时为二次函数，

判别准则仍然相同。


3. 错判情况:

取 $p = 1$ 的正态总体 $N(\mu_1, \sigma^2), N(\mu_2, \sigma^2), \mu_1 > \mu_2$ 的情况, 对于样本 x 的判别函数

$$W(x) = \frac{\left(x - \frac{\mu_1 + \mu_2}{2}\right)(\mu_1 - \mu_2)}{\sigma^2} = a \left(x - \frac{\mu_1 + \mu_2}{2}\right)$$

当 $x > \frac{\mu_1 + \mu_2}{2}$ 时, 样本 $x \in G_1$; 当 $x < \frac{\mu_1 + \mu_2}{2}$ 时, 样本 $x \in G_2$;

则样本 x 分别有概率 $P(1|2), P(2|1)$ 发生错判.



【例题 1】分别计算 $P(1|2), P(2|1)$.

4. 多个总体的距离判别: 设有 k 个总体 $G_1, \dots, G_k$, 判别函数

(1) 当 $\Sigma_1 = \dots = \Sigma_k$ (或估计量 $S_1 = \dots = S_k$) 时:

$$W_{ij}(X) = \left(X - \frac{\bar{X}_i + \bar{X}_j}{2}\right)' S^{-1}(\bar{X}_i - \bar{X}_j), \quad i, j = 1, 2, \dots, k$$

其中, $S = \frac{1}{n_1 + \dots + n_k - k} (L_1 + \dots + L_k)$. 判别准则:

$$\begin{cases} X \in G_i, & W_{ij}(X) > 0, \forall j \neq i \\ \text{待判}, & W_{ij}(X) = 0, \exists j \neq i \end{cases}$$

(2) 当 $\Sigma_i \neq \Sigma_j$ (或估计量 $S_i \neq S_j$) 时:

$$W_{ij}(X) = (X - \bar{X}_j)' S_j^{-1}(X - \bar{X}_j) - (X - \bar{X}_i)' S_i^{-1}(X - \bar{X}_i)$$

判别准则仍然相同.

5. 距离判别的局限性:

- (1) 只利用了特征量 (参数) 均值和协方差矩阵, 未涉及分布类型;
- (2) 距离判别与各总体出现的机会大小 (先验概率) 完全无关;
- (3) 距离判别没有考虑错判造成的损失.

三、Bayes 判别

1. 广义平方距离判别:

$$D^2(X, G_i) = d^2(X, G_i) + g_1(i) + g_2(i)$$

其中, $g_1(i) = \begin{cases} \ln|S_i|, & \text{组内 } \Sigma_i \text{ 不全相等} \\ 0, & \text{组内 } \Sigma_i \text{ 全相等} \end{cases}$, $g_2(i) = \begin{cases} -2 \ln|q_i|, & \text{先验概率 } q_i \text{ 不全相等} \\ 0, & \text{先验概率 } q_i \text{ 全相等} \end{cases}$.

当 $d^2(X, G_i)$ 不变时, 若某个 q_i 大 (总体 G_i 出现的机会大) 时, 则 $g_2(i)$ 变小, 故广义平方距离 $D^2(X, G_i)$ 也变小, 进而判定 X 为 G_i 的可能性变大.

判别准则:

$$\begin{cases} X \in G_i, & D^2(X, G_i) < D^2(X, G_j), \forall j \neq i \\ \text{待判}, & D^2(X, G_i) = D^2(X, G_j), \exists j \neq i \end{cases}$$

2. 错判概率的定义:

当样本 $X \in G_i$ 被判定到 G_j 中, 发生错判, 错判概率记作 $P(j|i)$, 且

$$P(j|i) = \int \dots \int_{D_j} f_i(x_1, \dots, x_p) dx_1 \dots dx_p = \int_{D_j} f_i(X) dX, \quad j \neq i$$

错判损失记作 $L(j|i)$.

3. 先验概率的平均损失:

$$\bar{L}(D) = \sum_{t=1}^k q_t \sum_{j=1}^k P(j|t) L(j|t)$$

4. Bayes 判别的定义:

对于空间 $\mathbf{R}^n$ 的一个划分 $D = \{D_1, \dots, D_k\}$, 当通过划分 D 来判别归类时所带来的平均损失最小. 设有 k 个总体 $G_1, \dots, G_k$ 相应的先验概率为 $q_1, \dots, q_k$, 若判别法 D^* 使得平均损失最小, 即有

$$\bar{L}(D^*) = \min \bar{L}(D)$$

则称判别法 D^* 满足 Bayes 判别. 设总体 G_i 的联合概率密度函数为 $f_i(X)$, 错判损失为 $L(j|i)$, 则 Bayes 判别的解 $D^* = \{D_1^*, \dots, D_k^*\}$ 为

$$D_t^* = \{X | h_t(X) < h_j(X), \forall j \neq t\}$$

其中, $h_j(X) = \sum_{i=1}^k q_i L(j|i) f_i(X)$, 表示把样本 X 判归 G_j 的平均损失.

【例题 2】求证: $D_t^* = \{X | h_t(X) < h_j(X), \forall j \neq t\}$ 为 Bayes 判别的解.

5. 错判损失都相等时 Bayes 判别的解:

$$D_t^* = \{X | q_t f_t(X) > q_j f_j(X), \forall j \neq t\}$$

【例题 3】求证: $D_t^* = \{X | q_t f_t(X) > q_j f_j(X), \forall j \neq t\}$ 为错判损失都相等时 Bayes 判别的解.

【例题 4】推导 $k = 2$ 时 Bayes 判别的解.

6. 正态总体的 Bayes 判别:

设 G_i 为正态总体 $N_p(\mu_i, \Sigma_i)$, 错判损失相等, 先验概率为 $q_1, \dots, q_k$,

(1) 当 $\Sigma_1 = \dots = \Sigma_k = \Sigma$ 时, Bayes 判别的解 $D^* = \{D_1^*, \dots, D_k^*\}$ 为

$$D_t^* = \{X | Y_t(X) > Y_j(X), \forall j \neq t\}$$

其中, $Y_j(X) = C_{j0} + C_j'X$ 为线性判别函数;

(2) 当 $\Sigma_i \neq \Sigma_j$ 时, Bayes 判别的解 $D^* = \{D_1^*, \dots, D_k^*\}$ 为

$$D_t^* = \{X | Z_t(X) > Z_j(X), \forall j \neq t\}$$

其中, $Z_j(X) = \ln q_j f_j(X) - d_0 = -\frac{1}{2}(-2 \ln q_j + \ln |S_j| + d_j^2(X)) = -\frac{1}{2}D_j^2(X)$

【例题 5】求证: 当 $\Sigma_1 = \dots = \Sigma_k = \Sigma$ 时 Bayes 判别函数为线性判别函数.

7. 正态总体 Bayes 判别与距离判别的比较:

(1) 协方差矩阵全相等时, Bayes 判别法在距离判别法基础上常数项增加考虑先验概率;

(2) 协方差矩阵不全相等时, Bayes 判别法与广义平方距离判别法一致.

四、Fisher 判别

1. Fisher 判别的定义:

设从 k 个总体分别取得 p 维观测值 $G_i: X_1, \dots, X_{n_i}$, $u(x) = a'X$ 为 X 向以 a 为法线方向上的投影,

则数据的投影为 $G_i: a'X_1, \dots, a'X_{n_i}$, 构成一元方差分析数据, 记 $\bar{X}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} X_j$, 组间平方和

$$SSG = \sum_{i=1}^k n_i (a' \bar{X}_i - a' \bar{X})^2 = a' \left(\sum_{i=1}^k n_i (\bar{X}_i - \bar{X})(\bar{X}_i - \bar{X})' \right) a = a' B a$$

其中, $\bar{X}$ 为所有样本的均值向量. 组内平方和

$$SSE = \sum_{i=1}^k \sum_{j=1}^{n_i} (a' X_j - a' \bar{X}_i)^2 = a' \left(\sum_{i=1}^k \sum_{j=1}^{n_i} (X_j - \bar{X}_i)(X_j - \bar{X}_i)' \right) a = a' A a$$

如果 k 组均值有显著差异, 则以下判别式应充分大

$$F = \frac{SSG/(k-1)}{SSE/(n-k)} = c \frac{a' B a}{a' A a}$$

2. Fisher 线性判别函数:

在 Fisher 准则下, 线性判别函数 $u(X) = a'X$ 的解 a 为特征方程 $|A^{-1}B - \lambda E| = 0$ 的最大特征值 λ_1 所对应的满足 $v_1' A v_1 = 1$ 的特征向量 v_1 , 判别效率为 $\Delta(v_1) = \lambda_1$.

3. Fisher 判别准则:

设 $A^{-1}B$ 的特征值为 $\lambda_1 \geq \dots \geq \lambda_r > 0$, 对应特征向量 $v_1, \dots, v_r$.

(1) 当 $r = 1$ 时, 仅有一个线性判别函数 $u(X) = v'X$.

对于 $k = 2$ 的情形, 设总体的样本均值为 $\bar{X}_1, \bar{X}_2$, 则线性判别函数值为 $\bar{u}_1 = v'\bar{X}_1, \bar{u}_2 = v'\bar{X}_2$,

令 $\bar{u} = \frac{\bar{u}_1 + \bar{u}_2}{2}$, $\bar{u}_1 > \bar{u}_2$, 投影后样本方差 $\hat{\sigma}_t = \frac{1}{n_t - 1} \sum_{i=1}^{n_t} (u_{ti} - \bar{u}_t)^2 = v'S_tv$, 则判别准则

$$\begin{cases} X \in G_1, & u(X) > \frac{\hat{\sigma}_2 \bar{u}_1 + \hat{\sigma}_1 \bar{u}_2}{\hat{\sigma}_1 + \hat{\sigma}_2} \\ X \in G_2, & u(X) < \frac{\hat{\sigma}_2 \bar{u}_1 + \hat{\sigma}_1 \bar{u}_2}{\hat{\sigma}_1 + \hat{\sigma}_2} \\ \text{待判}, & u(X) = \frac{\hat{\sigma}_2 \bar{u}_1 + \hat{\sigma}_1 \bar{u}_2}{\hat{\sigma}_1 + \hat{\sigma}_2} \end{cases}$$

(2) 当 $r > 1$ 时, 先取判别效率最大的线性判别函数 $u_1(X) = v'_1 X$, 对于 k 个总体的样本均值 $\bar{X}_1, \dots, \bar{X}_k$, 则线性判别函数值为 $\bar{u}_{11} = v'_1 \bar{X}_1, \dots, \bar{u}_{1k} = v'_1 \bar{X}_k$, 则判别准则

$$\begin{cases} X \in G_i, & \frac{|u_1(X) - \bar{u}_{1i}|}{\hat{\sigma}_i} = \min_{t=1, \dots, k} \frac{|u_1(X) - \bar{u}_{1t}|}{\hat{\sigma}_t} \\ \text{待判}, & \text{多个 } t \text{ 满足 } \min_{t=1, \dots, k} \frac{|u_1(X) - \bar{u}_{1t}|}{\hat{\sigma}_t} \end{cases}$$

此时将满足的序号 t 取判别效率次大的线性判别函数 $u_2(X) = v'_2 X$ 进行判别, 以此类推.

【例题 6】记二维正态总体 $N_2(\mu_i, \Sigma)$ 为 G_i ($i = 1, 2$), 来自 G_i 的样本数据阵为

$$X_1 = \begin{bmatrix} 2 & 12 \\ 4 & 10 \\ 3 & 8 \\ 3 & 10 \end{bmatrix}, X_2 = \begin{bmatrix} 5 & 7 \\ 3 & 9 \\ 4 & 5 \end{bmatrix}$$

设样本 $X_0 = \begin{bmatrix} 2 \\ 8 \end{bmatrix}$, 已知先验概率 $q_1 = 0.4$, $q_2 = 0.6$, $L(2|1) = L(1|2) = 1$,

- (1) 求两总体的样本组内离差矩阵 A_1, A_2 , 合并样本协差矩阵 S , 组间离差矩阵 B ;
- (2) 按距离准则对样本 X_0 进行判别分类;
- (3) 按 Bayes 准则对样本 X_0 进行判别分类;
- (4) 按 Fisher 准则对样本 X_0 进行判别分类.

五、逐步判别

1. 逐步判别的基本思想：

- ①在变量 $X_1, X_2, \dots, X_p$ 中，选择使 $\Lambda_i, i = 1, \dots, p$ 达到最小的变量作为第一个变量；
- ②在变量 $X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_p$ 中，选择使 $\Lambda_{1;j}, j = 1, \dots, i-1, i+1, \dots, p$ 达到最小的变量作为第二个变量；
- ③设已选择 r 个变量，则在未选中的变量中逐次选择使 $\Lambda_{1, \dots, r; j}$ 达到最小的变量作为第 $r+1$ 个变量，并检验新选的第 $r+1$ 个变量能否提供附加信息，如果不能则转入⑤，否则转入④；
- ④在已选择的 r 个变量中，考虑较早选的变量其重要性有没有较大变化，应及时把不能提供附加信息的变量剔除出去；
- ⑤当既不能选入新变量，又不能剔除已选择的变量时，利用已选择的变量建立判别函数。

2. 逐步判别的步骤：

假设挑选的变量次序是按自然的次序，即第 r 步正好选中 X_r ，并考察 Λ_r 是否落入接受域。

- ①对于 Λ_1 ，如果不显著，则没有变量可以选中，不能判别分析；如果显著，则进入下一步；
- ②在变量 $X_2, \dots, X_p$ 中，选择使 $\Lambda_{1;j}, j = 2, \dots, p$ 达到最小的变量作为第二个变量。
- ③设已选择 r 个变量 $X_1, X_2, \dots, X_r$ ，则在未选中的变量中逐次选择使 $\Lambda_{1, \dots, r; j}, j = r+1, \dots, p$ 达到最小的变量作为第 $r+1$ 个变量，并检验新选的第 $r+1$ 个变量能否提供附加信息，如果不能则转入⑤，否则转入④；
- ④在已选择的 r 个变量 $X_1, X_2, \dots, X_r$ 中，选择使 $\Lambda_{k; 1, \dots, k-1, k+1, \dots, r}$ 达到最小的变量，如果不显著，则将该变量剔除，继续④以考察余下的变量是否需要剔除，如果显著，则回到③；
- ⑤当既不能选入新变量，又不能剔除已选择的变量时，利用已选择的变量建立判别函数。

六、聚类分析的基本思想

1. 指标的尺度：

- (1) 间隔尺度：变量用连续的量来表示，如各种奖金、各种津贴等；
- (2) 有序尺度：指标用有序的等级来表示，如文化程度有次序关系，但没有数量表示；
- (3) 名义尺度：指标用一些类来表示，类之间既没有等级关系，也没有数量关系。

2. 样本距离的定义：

(1) 绝对值距离： $d_{ij} = \sum_{k=1}^p |x_{ik} - x_{jk}|$ ；平面距离： $d_{ij} = \sqrt{\sum_{k=1}^p |x_{ik} - x_{jk}|^2}$ ；

(2) Minkowski 距离： $d_{ij} = \left(\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right)^{\frac{1}{q}}$ ；

(3) Chebyshev 距离： $d_{ij} = \max_{1 \leq k \leq p} |x_{ik} - x_{jk}|$ ；

(4) 配合度： $d_{12} = \frac{m_2}{m_1 + m_2}$ ，其中 m_1 为配合的指标数， m_2 为不配合的指标数。

3. 样本距离的改进:

(1) 当各指标的测量值相差较大时, 先将数据标准化, 然后用标准化后的数据计算距离.

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad S_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{X}_j)^2}$$

则标准化距离 $x_{ij}^* = \frac{x_{ij} - \bar{X}_j}{S_j}$;

$$(2) \text{ LW 距离: } d_{ij} = \frac{1}{p} \sum_{k=1}^p \frac{|x_{ik} - x_{jk}|}{x_{ik} + x_{jk}};$$

$$(3) \text{ 统计距离: } d_{ij}^2 = (X_{(i)} - X_{(j)})' \Sigma^{-1} (X_{(i)} - X_{(j)}).$$

【例题 7】设正态总体 $G \sim N_2(0, \Sigma)$, 其中 $\Sigma = \begin{bmatrix} 1 & 0.9 \\ 0.9 & 1 \end{bmatrix}$, 求 $A = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, B = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 到 μ 的距离.

4. 指标距离的定义: 设指标向量 $(x_{1i}, \dots, x_{ni}), (x_{1j}, \dots, x_{nj})$,

$$(1) \text{ 夹角余弦: } C_{ij} = \frac{\sum_{k=1}^n x_{ki} x_{kj}}{\sqrt{\sum_{k=1}^n x_{ki}^2} \sqrt{\sum_{k=1}^n x_{kj}^2}};$$

$$(2) \text{ 相关系数: } C_{ij} = \frac{\sum_{k=1}^n (x_{ki} - \bar{X}_i)(x_{kj} - \bar{X}_j)}{\sqrt{\sum_{k=1}^n (x_{ki} - \bar{X}_i)^2} \sqrt{\sum_{k=1}^n (x_{kj} - \bar{X}_j)^2}}.$$

5. 类的定义:

5.1 设 T 为给定阈值, 如果 $\forall i, j \in G$ 有 $d_{ij} \leq T$, 则称 G 为一个类.


5.2 设 T 为给定阈值, 如果 $\forall i \in G$ 有 $\frac{1}{k-1} \sum_{j \in G} d_{ij} \leq T$, 则称 G 为一个类.

5.3 设 T, V 为给定阈值, 如果 $\forall i, j \in G$ 有 $\frac{1}{k(k-1)} \sum_{i \in G} \sum_{j \in G} d_{ij} \leq T$, $d_{ij} \leq V$, 则称 G 为一个类.


5.4 设 T 为给定阈值, 如果 $\forall i \in G$ 都 $\exists j \in G$ 使得 $d_{ij} \leq T$, 则称 G 为一个类.

6. 类间距离的定义:

(1) 最短距离: $D_{\min}(p, q) = \min\{d_{ij} | i \in G_p, j \in G_q\}$;




(2) 最长距离: $D_{\max}(p, q) = \max\{d_{ij} | i \in G_p, j \in G_q\}$;



(3) 中心法: $D_c(p, q) = d_{\bar{x}_p \bar{x}_q}$;

(4) 类平均法: $D_G(p, q) = \frac{1}{n_p n_q} \sum_{i \in G_p} \sum_{j \in G_q} d_{ij}$;




(5) 离差平方和法: $D_w^2(p, q) = D_{p+q} - D_p - D_q = \frac{n_p n_q}{n_p + n_q} D_c^2(p, q)$

$$D_p = \sum_{i=1}^{n_p} (X_i - \bar{X}_p)' (X_i - \bar{X}_p) \quad D_q = \sum_{j=1}^{n_q} (X_j - \bar{X}_q)' (X_j - \bar{X}_q)$$

$$D_{p+q} = \sum_{k=1}^{n_p+n_q} (X_k - \bar{X})' (X_k - \bar{X}), \quad \bar{X} = \frac{1}{n_p + n_q} \sum_{k \in G_p \cup G_q} x_k$$

七、系统聚类法

1. 系统聚类法的一般步骤:



2. 最短距离法与最长距离法: 分别使用 $D_{\min}(p, q)$, $D_{\max}(p, q)$ 准则来衡量类间距离.

【例题 8】分别用最短距离法与最长距离法对样本进行聚类，其中样本距离矩阵如下：

$$D = \begin{bmatrix} 0 & 3681.88 & 2863.01 & 2091.25 & 1631.27 \\ 3681.88 & 0 & 6030.37 & 5333.5 & 4936.59 \\ 2863.01 & 6030.37 & 0 & 923.14 & 1474.24 \\ 2091.25 & 5333.5 & 923.14 & 0 & 650.44 \\ 1631.27 & 4936.59 & 1474.24 & 650.44 & 0 \end{bmatrix}$$

3. 最短距离法的局限性：具有链接聚合的趋势

当合并类与类之间的距离为所有距离中的最短的两类后，与其他类的距离缩小，容易形成比较大的类，其中大部分样品都被聚在该类中，在树状聚类图中呈现延伸的链状结构。

4. 最长距离法的优越性：克服最短距离法链接聚合的缺陷

两类合并后与其他类的距离是原来两个类中的最大距离，加大合并后的类与其他类的距离。

5. 中心法：使用 $D_c(p, q)$ 准则来衡量类间距离，递推公式：

$$D_c^2(k, p+q) = \frac{n_p}{n_p + n_q} D_c^2(k, p) + \frac{n_q}{n_p + n_q} D_c^2(k, q) - \frac{n_p n_q}{(n_p + n_q)^2} D_c^2(p, q)$$

6. 类平均法：使用两类元素两两之间的平均平方距离准则来衡量类间距离，递推公式：

$$D_G^2(k, p+q) = \frac{n_p}{n_p + n_q} D_G^2(k, p) + \frac{n_q}{n_p + n_q} D_G^2(k, q)$$

$$\text{其中, } D_G^2(p, q) = \frac{1}{n_p n_q} \sum_{i \in G_p} \sum_{j \in G_q} d_{ij}^2.$$

可变类平均法：

$$D_G^2(k, p+q) = (1 - \beta) \left(\frac{n_p}{n_p + n_q} D_G^2(k, p) + \frac{n_q}{n_p + n_q} D_G^2(k, q) \right) + \beta D_G^2(p, q)$$

7. 离差平方和法：使用 $D_w^2(p, q)$ 准则来找出最小的分类，总离差平方和计算公式：

$$L = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)' (X_{ij} - \bar{X}_i) = \sum_{i=1}^k L_i$$

其中，对于将 n 个样本分为 k 类共有 $\frac{1}{k} \sum_{i=0}^k (-1)^{k-i} C_k^i i^n$ 种（容斥原理）。

Ward 局部最优算法：让 n 个样品各自成一类，每次缩小一类，离差平方和增大，选择使 L 增加最小的两类合并，直到所有的样品归为一类为止，递推公式：

$$D_w^2(k, p+q) = \frac{n_p + n_k}{n_p + n_q + n_k} D_w^2(k, p) + \frac{n_q + n_k}{n_p + n_q + n_k} D_w^2(k, q) - \frac{n_k}{n_p + n_q + n_k} D_w^2(p, q)$$

8. 分类数的确定：

- (1) 任何类都必须在邻近各类中是突出的，即各类中心之间距离必须足够大；
- (2) 各类所包含的元素都不应过多；
- (3) 分类的数目应该符合使用的目的；
- (4) 若采用几种不同的聚类方法处理，则在各自的聚类图上应发现相同的类。

9. 系统聚类法的单调性：满足 $\{D_k\}$ 单调递增的系统聚类法

满足单调性的聚类方法符合系统聚类的思想：先结合的类关系较近，后结合的类关系较远。

10. 系统聚类法的空间扩张与收缩：

(1) A 比 B 空间扩张：

A 聚类法满足 D_k 中所有元素均大于或等于 B 聚类法 D_k 中所有元素；

(2) A 比 B 空间收缩：

A 聚类法满足 D_k 中所有元素均小于或等于 B 聚类法 D_k 中所有元素；

过于收缩的聚类法不够灵敏，过于扩张的聚类法在样本大时容易失真。

11. 系统聚类法的一般形式：

$$D^2(k, p+q) = \alpha_p D^2(k, p) + \alpha_q D^2(k, q) + \beta D^2(p, q) + \gamma |D^2(k, p) - D^2(k, q)|$$

方法	α_p	α_q	β	γ
最短距离法	$\frac{1}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$
最长距离法	$\frac{1}{2}$	$\frac{1}{2}$	0	$\frac{1}{2}$
中间距离法	$\frac{1}{2}$	$\frac{1}{2}$	$-\frac{1}{4}$	0
中心法	$\frac{n_p}{n_p + n_q}$	$\frac{n_q}{n_p + n_q}$	$-\alpha_p \alpha_q$	0
类平均法	$\frac{n_p}{n_p + n_q}$	$\frac{n_q}{n_p + n_q}$	0	0
可变类平均法	$(1 - \beta) \frac{n_p}{n_p + n_q}$	$(1 - \beta) \frac{n_q}{n_p + n_q}$	$\beta < 1$	0
可变法	$\frac{1 - \beta}{2}$	$\frac{1 - \beta}{2}$	$\beta < 1$	0
离差平方和法	$\frac{n_p + n_k}{n_p + n_q + n_k}$	$\frac{n_q + n_k}{n_p + n_q + n_k}$	$\frac{-n_k}{n_p + n_q + n_k}$	0

12. 常见系统聚类法的性质比较:

方法	单调性	空间扩张与收缩
最短距离法	√	空间收缩
最长距离法	√	空间扩张
中间距离法	×	—
中心法	×	空间收缩
类平均法	√	中等（比较对象）
可变类平均法	√	—
可变法	√	—
离差平方和法	√	空间扩张

八、K-均值法

1. 非谱系聚类:

非谱系聚类法把样品（而不是变量）聚集成 K 个类的集合，类的个数可以预先给定或者在聚类过程中确定。

2. K-均值法的基本思想:

- （1）把样品粗略分成 K 个初始类；
- （2）逐个分派样品到其最近均值类中，重新计算接受新样品的类和失去样品的类的均值；
- （3）重复第（2）步，直到各类无元素进出。

3. 样品的最终聚类在某种程度上依赖于最初的划分，或种子点的选择。

为了检验聚类的稳定性，可用一个新的初始分类重新检验整个聚类算法。

4. K-均值法的局限性:

- （1）如果有两个或多个种子点无意中跑到一个类内，则其聚类结果将很难区分；
- （2）局外干扰的存在将至少产生一个样品非常分散的类；
- （3）即使已知总体由 K 个类组成，抽样方法可能造成属于稀疏类的数据不出现在样本中，导致无意义的聚类。

【例题 9】将样本 $A(5,3), B(-1,1), C(1,-2), D(-3,-2)$ 用 K-均值法聚为两类。

九、有序样本聚类

1. 有序样本聚类的基本思想：

当分类的样本不是相互独立的，而与时间的顺序密切相关时，需要找出一些分点，将样本分割成几个分段，每个分段看作一类，即要求一个分割能使各段内部样本间的差异最小，而各段之间样本的差异最大。

2. 所有可能的分类数目：

设 $x_1, \dots, x_n$ 为一组有序样本，则该组样本被分为 k 类的可能情况有 C_{n-1}^{k-1} 种。

3. Fisher 算法：

(1) 定义类的直径：设类 $G_{ij} = \{x_i, x_{i+1}, \dots, x_j\}$ ，均值为 $\bar{x}_{ij}$ ，则类 G_{ij} 直径为

$$D(G_{ij}) = \sum_{l=i}^j (x_l - \bar{x}_{ij})' (x_l - \bar{x}_{ij})$$

(2) 定义目标函数：若将待聚类的 n 个有序样本分为 k 类

$$D_{nk}: \{x_{i_1}, \dots, x_{i_2-1}\}, \{x_{i_2}, \dots, x_{i_3-1}\}, \dots, \{x_{i_k}, \dots, x_n\}$$

则目标函数为当前分割方法下的各类离差平方和

$$SSE(D_{nk}) = \sum_{j=1}^k D(G_{i_j, i_{j+1}-1})$$

(3) 寻求目标函数的最小值：采用递推公式

$$SSE(D_{nk}) = \min_{k \leq j \leq n} \{SSE(D_{j-1, k-1}) + D(G_{jn})\}$$

当求得 j_k 满足 $SSE(D_{nk}) = SSE(D_{j_k-1, k-1}) + D(G_{j_k n})$ 时，即确定 $G_{j_k n} = \{x_{j_k}, x_{j_k+1}, \dots, x_n\}$ ，以此类推求得 $j_k - 1$ ，确定 $G_{j_k-1, n}$ ，从而确定所有 k 个类。

十、模糊聚类分析

1. 模糊矩阵的定义：设矩阵元素取值在 $[0,1]$ 范围内，则称矩阵为模糊矩阵。

2. 模糊矩阵的运算： $C = AB$ ，其中

$$c_{ij} = \max_{1 \leq k \leq p} \{\min\{a_{ik}, b_{kj}\}\}$$

3. 模糊 C-均值聚类 (FCM) 的基本思想：

设将样本 $x_1, \dots, x_n$ 划分为 c 类，样本 x_i 属于类 g 的隶属度为 u_{ig} ，隶属度矩阵 U ，各类的类中心 $V = (v_1, \dots, v_c)$ ，则 FCM 聚类方法即求解优化问题：

$$\begin{aligned} & \min_{U, V} \sum_{i=1}^n \sum_{g=1}^c (u_{ig})^m \|x_i - v_g\|_A^2 \\ & \text{s.t.} \begin{cases} \sum_{g=1}^c u_{ig} = 1 \\ m \geq 1 \end{cases} \end{aligned}$$

其中， A -范数： $\|x_i - v_g\|_A^2 = (x_i - v_g)' A (x_i - v_g)$ 。

算法:

①给定 c, m, A , 最大迭代次数 N , 误差界 ε ;

②给定初始值 V_0 , $n = 1$;

③当 $n < N$ 时, 用 V_{n-1} 计算 U_n , 其中

$$u_{ig} = \frac{1}{\sum_{j=1}^c \left(\frac{\|x_i - v_g\|_A}{\|x_i - v_j\|_A} \right)^{\frac{1}{m-1}}}$$

再用 U_n 计算 V_n , 其中

$$v_g = \frac{\sum_{i=1}^n (u_{ig})^m x_i}{\sum_{i=1}^n (u_{ig})^m}$$

④若 $\|V_n - V_{n-1}\| \leq \varepsilon$, 则停止迭代, 得到 U, V ; 否则, $n = n + 1$, 转③.

第 7 章 主成分分析与因子分析

一、主成分分析的基本思想

1. 主成分分析的基本要求:

- (1) 每一个主成分都是各原始变量的线性组合;
- (2) 主成分的数目少于原始变量的数目且保留原始变量的绝大多数信息;
- (3) 各主成分之间互不相关.

2. 主成分的定义:

设 $X = (X_1, \dots, X_p)'$ 为 p 维向量, 均值向量为 μ , 协方差矩阵为 Σ , 作线性变换

$$Y = U'X = \begin{cases} Y_1 = u_1'X = u_{11}X_1 + u_{21}X_2 + \dots + u_{p1}X_p \\ Y_2 = u_2'X = u_{12}X_1 + u_{22}X_2 + \dots + u_{p2}X_p \\ \dots \\ Y_p = u_p'X = u_{1p}X_1 + u_{2p}X_2 + \dots + u_{pp}X_p \end{cases}$$

且有 $D(Y_i) = u_i'\Sigma u_i$, $\text{cov}(Y_i, Y_j) = u_i'\Sigma u_j$, 若 $Y_i = u_i'X$ 满足

$$\begin{cases} (1) u_i'u_i = 1; & \text{约束条件} \\ (2) u_i'\Sigma u_j = 0; & Y_i, Y_j \text{ 不相关} \\ (3) D(Y_i) = \max_{\substack{\text{substack } v'v=1, v'\Sigma u_j=0 \\ j=1, \dots, i-1}} D(v'X) & Y_i \text{ 是原变量的线性组合且方差递减} \end{cases}$$

则称 Y_i 为 X 的第 i 主成分.


3. 主成分的几何意义:

主成分的总数由原变量的个数确定, 对于 p 个原变量, 其主成分有 p 个;

主成分将原变量构成的坐标系旋转, 产生新坐标系:

$$Y = U'X$$

其中, U 为旋转变换矩阵; 使新坐标轴通过样本变差最大的方向, 即具有最大的样本方差.



(p 维正态分布的主成分是超椭圆的主轴)

经过旋转后, 样本点在 Y_1 轴上的离散程度最大, 即变量 Y_1 代表了原始数据的绝大部分信息.

以二维变量 $X = (X_1, X_2)'$ 为例, 其旋转为

$$\begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = U'X$$

二、主成分的求解与性质

1. 主成分的求解方法:

主成分的求解为一个条件极值问题, 目标函数与约束条件为 $\max D(Y_i)$
 $s.t. u_i' u_i = 1$.

(1) 构造 Lagrange 函数:

$$L(u_i; \lambda) = u_i' \Sigma u_i - \lambda(u_i' u_i - 1)$$

(2) 求解方程组:

$$\begin{cases} \frac{\partial L}{\partial u_i} = 2\Sigma u_i - 2\lambda u_i = 0 \\ \frac{\partial L}{\partial \lambda} = u_i' u_i - 1 = 0 \end{cases}$$

即

$$\Sigma u_i = \lambda_i u_i$$

其中 λ_i 为 Σ 的特征值, u_i 为 Σ 的对应于特征值 λ_i 的特征向量, 从而 $\lambda_i = u_i' \Sigma u_i = D(Y_i)$.

2. 主成分的充要条件:

设 $Y = (Y_1, \dots, Y_p)'$ 为 p 维向量, 其分量 Y_i 依次是 X 的第 i 主成分的充分必要条件是

(1) Y 是 X 的正交变换 $Y = U'X$, 其中 U 为正交矩阵;

(2) $U' \Sigma U = D(Y) = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \end{bmatrix}$, $\lambda_1 \geq \dots \geq \lambda_p$.

【例题 1】求证: 上述命题成立.

3. 因子负荷量: 主成分 Y_j 与原始变量 X_i 的相关系数 $r(Y_j, X_i)$ 称为因子负荷量.

因子负荷量是主成分解释中的重要解释依据, 因子负荷量的绝对值大小刻画了该主成分的主要意义及其成因.

4. 第 i 个主成分的方差贡献率:

$$\frac{\lambda_i}{\lambda_1 + \dots + \lambda_p}$$

前 m 个主成分的累计贡献率: ($m \leq p$)

$$\frac{\lambda_1 + \dots + \lambda_m}{\lambda_1 + \dots + \lambda_p}$$

5. 主成分的性质:

(1) 原总体的各分量方差和可以分解为不相关的主成分的方差和:

$$\sum_{i=1}^p D(X_i) = \sum_{i=1}^p \lambda_i$$

【例题 2】求证: 上述命题成立.

(2) 因子负荷量与系数向量成正比:

$$r(Y_j, X_i) = \frac{\sqrt{\lambda_j} u_{ij}}{\sqrt{D(X_i)}}$$

【例题 3】求证: 上述命题成立.

(3) 对于相关矩阵

$$R(Y_j, X_i) = \begin{bmatrix} r(Y_1, X_1) & r(Y_2, X_1) & \cdots & r(Y_p, X_1) \\ r(Y_1, X_2) & r(Y_2, X_2) & \cdots & r(Y_p, X_2) \\ \vdots & \vdots & \ddots & \vdots \\ r(Y_1, X_p) & r(Y_2, X_p) & \cdots & r(Y_p, X_p) \end{bmatrix}$$

①对每行, 有 $\sum_{j=1}^p r^2(Y_j, X_i) = \sum_{j=1}^p \frac{\lambda_j u_{ij}^2}{D(X_i)} = 1$; ②对每列, 有 $\sum_{i=1}^p r^2(Y_j, X_i) D(X_i) = \lambda_j$.

【例题 4】求证: 上述命题成立.

6. 前 m 个主成分对原始变量 X_i 的贡献率 (解释程度): ($m \leq p$)

$$v_i^{(m)} = \sum_{j=1}^m r^2(Y_j, X_i) = \sum_{j=1}^m \frac{\lambda_j u_{ij}^2}{D(X_i)}$$

7. 标准化数据求主成分:

对样本数据矩阵先进行标准化

$$X_i^* = \frac{X_i - \mu_i}{\sqrt{D(X_i)}}$$

则

$$E(X^*) = 0, \quad \text{cov}(X_i^*, X_j^*) = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix} = R$$

此时只需要利用

$$Ru_i^* = \lambda_i^* u_i^*$$

即可求得主成分, 其中 λ_i^* 为 R 的特征值, u_i^* 为 R 的对应于特征值 λ_i^* 的特征向量, .

8. 标准化主成分的性质:

(1) 标准化主成分的方差和为 p :

$$\sum_{i=1}^p D(X_i^*) = \sum_{i=1}^p \lambda_i^* = p$$

【例题 5】求证: 上述命题成立.

(2) 因子负荷量与系数向量成正比:

$$r(Y_j^*, X_i^*) = \sqrt{\lambda_j^*} u_{ij}^*$$

(3) 对于相关矩阵

$$R(Y_j^*, X_i^*) = \begin{bmatrix} r(Y_1^*, X_1^*) & r(Y_2^*, X_1^*) & \cdots & r(Y_p^*, X_1^*) \\ r(Y_1^*, X_2^*) & r(Y_2^*, X_2^*) & \cdots & r(Y_p^*, X_2^*) \\ \vdots & \vdots & \ddots & \vdots \\ r(Y_1^*, X_p^*) & r(Y_2^*, X_p^*) & \cdots & r(Y_p^*, X_p^*) \end{bmatrix}$$

①对每行, 有 $\sum_{j=1}^p r^2(Y_j^*, X_i^*) = \sum_{j=1}^p \lambda_j^* u_{ij}^{*2} = 1$; ②对每列, 有 $\sum_{i=1}^p r^2(Y_j^*, X_i^*) = \lambda_j^*$.

9. 样本主成分:

实际问题中, 协方差矩阵 Σ 与相关矩阵 R 未知, 需要通过样本来估计:

$$S = \frac{1}{n-1} \sum_{i=1}^n (X_{(i)} - \bar{X})(X_{(i)} - \bar{X})'$$

$$r_{ij} = \frac{S_{ij}}{\sqrt{S_{ii}}\sqrt{S_{jj}}}$$

当样本观测数据都已标准化后, 此时样本协方差矩阵即样本相关矩阵 R , 且有

$$R = \frac{1}{n-1} X^{*'} X^*$$

三、主成分分析的一般理论

1. 是否对原始数据进行标准化:

标准化过程是减小变量间离散程度的过程, 会概括数据重要信息:

- (1) 对于度量单位不同取值范围差异大的指标, 考虑将数据标准化后进行主成分分析;
- (2) 对于同度量或取值范围在同量级的数据, 直接从协方差矩阵求解主成分为宜.

2. 主成分分析的数据总体:

主成分分析不要求数据来自正态总体, 而直接对矩阵结构的分析, 其中用到的主要是矩阵运算的技术及矩阵对角化和矩阵的谱分解技术.

3. 主成分分析的信息重叠 (原始变量存在多重共线性):

主成分分析方法适用于变量之间存在较强相关性的数据, 如果原始数据相关性较弱, 所得各个主成分概括原始变量信息的能力差别不大.

对原始变量存在多重共线性的问题, 在应用主成分分析时应该考虑所选取的初始变量处理.

【例题 6】推导在主成分分析中, 当 $\lambda_p \approx 0$ 时, 原始变量存在多重共线性.

4. 主成分的个数及其解释:

(1) 主成分的个数要求:


m 个主成分所反映的信息与原来 p 个变量提供的信息相差不大, 且能对数据意义进行解释.

(2) 主成分的选择标准:

①按照累计贡献率达到一定程度来确定;

②先计算所求的 p 个特征值的均值 $\bar{\lambda}$, 取大于 $\bar{\lambda}$ 的特征值个数为主成分的个数.

5. 主成分分析的一般过程:



四、因子分析的基本思想

1. 公共因子与特殊因子:

根据相关性大小将相关性较高的原始变量分为一组, 将原始变量分解成少数几个不可测的公共因子的线性函数和特殊因子.

2. 正交因子模型:

设有 n 个样本, 每个样本包含 p 个维度 $X = (X_1, \dots, X_p)$, 满足 $E(X) = \mu$, $D(X) = \Sigma$, 其中

(1) 公共因子从原始变量各变量中提取出来的共同特征, 是不可观测的随机变量, 记作

$$F = (F_1, \dots, F_m)' , \quad m < p$$

设定 $E(F) = 0, D(F) = \begin{bmatrix} 1 & & \\ & \ddots & \\ & & 1 \end{bmatrix}$, 即公共因子均值为0, 方差为1, 互不相关;

(2) 特殊因子是原始变量各分量 X_i 所特有的特征, 记作 $\varepsilon = (\varepsilon_1, \dots, \varepsilon_p)'$, 设定 $E(\varepsilon) = 0$,

$D(\varepsilon) = \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_p^2 \end{bmatrix}$, $\text{cov}(F, \varepsilon) = 0$, 即特殊因子均值为0, 方差为 σ_i^2 , 互不相关且与公共因子互不相关. 则称以下原始变量的公共因子和特殊因子的线性组合

$$\begin{cases} X_1 - \mu_1 = a_{11}F_1 + a_{12}F_2 + \dots + a_{1m}F_m + \varepsilon_1 \\ X_2 - \mu_2 = a_{21}F_1 + a_{22}F_2 + \dots + a_{2m}F_m + \varepsilon_2 \\ \vdots \\ X_p - \mu_p = a_{p1}F_1 + a_{p2}F_2 + \dots + a_{pm}F_m + \varepsilon_p \end{cases}$$

为正交因子模型, 即

$$X - \mu = AF + \varepsilon$$

其中, 系数矩阵 A 称为因子载荷矩阵, 元素 a_{ij} 称为第 i 个变量在第 j 个因子上的载荷.

3. 正交因子模型的协方差结构:

$$\begin{aligned} \text{cov}(X, F) &= A \\ D(X) - D(\varepsilon) &= AA' \end{aligned}$$

【例题 7】求证: 正交因子模型的协方差结构 $\text{cov}(X, F) = A$, $D(X) - D(\varepsilon) = AA'$.

4. 因子载荷矩阵不唯一: 对于任意正交矩阵 T , 公共因子 $T'F$ 的因子载荷矩阵为 AT , 即

$$X - \mu = ATT'F + \varepsilon$$

故正交旋转后仍满足正交因子模型.

5. 正交因子模型不受量纲影响: 设 $Y = DX$, 其中 D 为对角矩阵, 则有 $E(Y) = D\mu$,

$$D(Y) = DAA'D' + DD(\varepsilon)D'.$$

6. 因子载荷的统计意义：度量原始变量 X_i 依赖于公共因子 F_j 的比重

$$a_{ij} = \text{cov}(X_i, F_j)$$

【例题 8】求证：因子载荷是原始变量 X_i 与公共因子 F_j 的协方差。

7. 变量共同度与剩余方差：

因子载荷矩阵 A 中第 i 行元素的平方和为变量 X_i 的共同度：

$$h_i^2 = \sum_{j=1}^m a_{ij}^2$$

从而变量 X_i 的方差是变量共同度与剩余方差的和：

$$D(X_i) = h_i^2 + D(\varepsilon_i)$$

变量共同度 h_i^2 反映了变量 X_i 对全部公共因子的依赖程度，剩余方差 $D(\varepsilon_i)$ 反映了由仅与变量 X_i 有关的特定因子 ε_i 产生的方差。

【例题 9】求证： $D(X_i) = h_i^2 + D(\varepsilon_i)$ 。

8. 公共因子的方差贡献：

因子载荷矩阵 A 中第 j 列元素的平方和为公共因子 F_j 的方差贡献：

$$q_j^2 = \sum_{i=1}^p a_{ij}^2$$

方差贡献 q_j^2 反映了公共因子 F_j 对全部变量的解释程度。

9. 标准化的正交因子模型：

$$X^* = AF^* + \varepsilon$$


在标准化变量情形下，因子载荷是原始变量 X_i 与公共因子 F_j 的相关系数：

$$a_{ij} = r(X_i^*, F_j^*)$$

变量 X_i 的方差是变量共同度与剩余方差的互补和：

$$D(X_i) = h_i^2 + D(\varepsilon_i) = 1$$

10. 因子分析的一般过程：



五、因子载荷矩阵的求解与性质

1. 主成分法:

从样本协方差阵 S 出发, 设其特征值为 $\lambda_1 \geq \dots \geq \lambda_p$, 对应特征向量为 $u_1, \dots, u_p$, 则

$$S = \sum_{i=1}^p \lambda_i u_i u_i' = U_1 U_1' + U_2 U_2'$$

其中, $U_1 = (\sqrt{\lambda_1}u_1, \dots, \sqrt{\lambda_m}u_m)$, $U_2 = (\sqrt{\lambda_{m+1}}u_{m+1}, \dots, \sqrt{\lambda_p}u_p)$, 则选出 m 个主成分, 估计

$$\hat{A} = U_1, \quad \hat{D}(\varepsilon) = U_2 U_2'$$

即在主成分与原始变量的关系中 $Y = U'X$:

$$\begin{cases} Y_1 = u_{11}X_1 + u_{12}X_2 + \dots + u_{1p}X_p \\ Y_2 = u_{21}X_1 + u_{22}X_2 + \dots + u_{2p}X_p \\ \vdots \\ Y_p = u_{p1}X_1 + u_{p2}X_2 + \dots + u_{pp}X_p \end{cases}$$

利用正交线性变数替换 $X = UY$:

$$\begin{cases} X_1 = u_{11}Y_1 + u_{12}Y_2 + \dots + u_{1p}Y_p \\ X_2 = u_{21}Y_1 + u_{22}Y_2 + \dots + u_{2p}Y_p \\ \vdots \\ X_p = u_{p1}Y_1 + u_{p2}Y_2 + \dots + u_{pp}Y_p \end{cases}$$

选取前 m 个为主成分 $Y_1, \dots, Y_m$, 令其余 $Y_{m+1}, \dots, Y_p$ 构成特殊因子, 则有

$$\begin{cases} X_1 = u_{11}Y_1 + u_{12}Y_2 + \dots + u_{1m}Y_m + \varepsilon_1 \\ X_2 = u_{21}Y_1 + u_{22}Y_2 + \dots + u_{2m}Y_m + \varepsilon_2 \\ \vdots \\ X_p = u_{p1}Y_1 + u_{p2}Y_2 + \dots + u_{pm}Y_m + \varepsilon_p \end{cases}$$

只需令 $F_i = \frac{Y_i}{\sqrt{\lambda_i}}$, 即可化为正交因子模型

$$\begin{cases} X_1 = \sqrt{\lambda_1}u_{11}F_1 + \sqrt{\lambda_2}u_{12}F_2 + \dots + \sqrt{\lambda_m}u_{1m}F_m + \varepsilon_1 \\ X_2 = \sqrt{\lambda_1}u_{21}F_1 + \sqrt{\lambda_2}u_{22}F_2 + \dots + \sqrt{\lambda_m}u_{2m}F_m + \varepsilon_2 \\ \vdots \\ X_p = \sqrt{\lambda_1}u_{p1}F_1 + \sqrt{\lambda_2}u_{p2}F_2 + \dots + \sqrt{\lambda_m}u_{pm}F_m + \varepsilon_p \end{cases}$$

其中, $\hat{A} = U_1 = (\sqrt{\lambda_1}u_1, \dots, \sqrt{\lambda_m}u_m)$, $\hat{D}(\varepsilon) = U_2 U_2' = S_{ii} - \hat{h}_i^2$.

2. 主成分法中公共因子个数 m 的取值:

- (1) 根据实际问题的意义或专业理论知识来确定;
- (2) 按累计方差贡献率确定.

【例题 10】 设 $\varepsilon = S - (\hat{A}\hat{A}' + \hat{D}(\varepsilon))$, 求证: $Q(m) = \text{tr}(\varepsilon'\varepsilon) \leq \lambda_{m+1}^2 + \dots + \lambda_p^2$.

3. 主轴因子法:

从约相关矩阵 $R^* = R - D(\varepsilon) = AA'$ 出发求解主成分, 按主成分法同样过程即可.

4. 最大似然估计法:

设 $X_1, X_2, \dots, X_p$ 为来自正态总体 $N_n(\mu, \Sigma)$ 的样本, 其中 $\Sigma = AA' + D(\varepsilon)$, 则似然函数

$$L(\mu, \Sigma) = \frac{1}{(\sqrt{2\pi})^{np} (\sqrt{|\Sigma|})^n} e^{-\frac{1}{2} \text{tr} \left(\Sigma^{-1} \left(\sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})' + n(\bar{X} - \mu)(\bar{X} - \mu)' \right) \right)}$$

若令 $A'D^{-1}(\varepsilon)A = D$, 其中 D 为对角矩阵, 则可用数值方法得到最大似然估计 $\hat{A}$ 与 $\hat{D}(\varepsilon)$.

5. 因子旋转:

由因子载荷矩阵不唯一, 为找到意义更为明确、实际意义更明显的公共因子, 即对初始因子载荷进行旋转, 使得旋转后原始变量 X_i 的共同度 h_i^2 并不改变, 而公共因子 F_i 对原始变量的贡献 q_i^2 与原来不同, 从而得到较好的公共因子.

6. 正交因子旋转:

$$X^* = ATT'F^* + \varepsilon$$

正交旋转后仍满足正交因子模型, 即经过正交旋转得到的新的公共因子仍然保持彼此独立的性质, 而斜交旋转则放弃因子之间彼此独立的限制, 因而可能达到更为简洁的形式, 其实际意义也更容易解释.

7. 因子得分:

把公共因子表示成变量的线性组合, 或对每一个样本计算公共因子的估计值, 即因子得分. 在因子模型中, 公共因子的个数少于原始变量的个数, 且公共因子是不可观测的隐变量, 载荷矩阵 A 不可逆, 因而不能直接求得公共因子用原始变量表示的精确线性组合:

*回归方程求线性组合系数的估计值:

$$F_j = \beta_{j1}X_1 + \beta_{j2}X_2 + \dots + \beta_{jp}X_p + \varepsilon_j$$

考虑标准化变量的回归方程:

$$F_j^* = \beta_{j1}X_1^* + \beta_{j2}X_2^* + \dots + \beta_{jp}X_p^*$$

则有公共因子得分估计:

$$\hat{F} = A'R^{-1}X$$

其中, A 为因子载荷矩阵; R 为原始变量的相关阵; X 为原始变量.

六、主成分分析与因子分析的区别

1. 因子分析把诸多变量看成是由一些对每个变量都有作用的公共因子和一些仅对该变量有作用的特殊因子的线性组合, 目的是从数据中探查能对变量起解释作用的公共因子、特殊因子与组合系数; 主成分分析从空间生成的角度寻找能解释诸多变量绝大部分变异的几组彼此不相关的新变量(即主成分).

2. 因子分析把变量表示成各因子的线性组合; 主成分分析中, 把主成分表示成各变量的线性组合.

3. 主成分分析中, 当给定的协方差矩阵或者相关矩阵的特征值唯一时, 主成分一般固定; 因子分析中, 因子不是固定的, 可以旋转得到不同的因子.

第8章 对应分析与典型相关分析

一、对应分析的基本思想

1. 列联表:

设特性 A 有 p 类, 特性 B 有 q 类, 属于 A_i 和 B_j 的个体数目为 n_{ij} , 则列联表:

		特性 B			合计
		B_1	...	B_q	
特性 A	A_1	p_{11}	...	p_{1q}	$p_{1\cdot}$
	$\vdots$	$\vdots$	p_{ij}	$\vdots$	$\vdots$
	A_p	p_{p1}	...	p_{pq}	$p_{p\cdot}$
合计		$p_{\cdot 1}$	...	$p_{\cdot q}$	1

2. 独立性检验:

$$H_0: p_{i\cdot} p_{\cdot j} = p_{ij} \leftrightarrow H_1: p_{i\cdot} p_{\cdot j} \neq p_{ij}$$

构造检验统计量:

$$\chi^2 = \sum_{i=1}^p \sum_{j=1}^q \left(\frac{n_{ij} - \hat{E}(n_{ij})}{\sqrt{\hat{E}(n_{ij})}} \right)^2 = n \sum_{i=1}^p \sum_{j=1}^q \frac{(p_{ij} - p_{i\cdot} p_{\cdot j})^2}{p_{i\cdot} p_{\cdot j}} \stackrel{\text{在 } H_0 \text{ 下}}{\sim} \chi^2((p-1)(q-1))$$

检验拒绝域:

$$W = \{\chi^2 > \chi_{1-\alpha}^2((p-1)(q-1))\}$$

3. 对应分析是 R 型因子分析与 Q 型因子分析的结合, 利用降维的思想来达到简化数据结构的目的, 同时对数据表中的行与列进行处理.

4. 行剖面、列剖面:

设 $P_i = (p_{i1}, p_{i2}, \dots, p_{iq})'$, $P_j = (p_{1j}, p_{2j}, \dots, p_{pj})'$, 则

行剖面条件概率向量: $P_i^r = \left(\frac{p_{i1}}{p_{i\cdot}}, \frac{p_{i2}}{p_{i\cdot}}, \dots, \frac{p_{iq}}{p_{i\cdot}} \right)'$, 列剖面条件概率向量: $P_j^c = \left(\frac{p_{1j}}{p_{\cdot j}}, \frac{p_{2j}}{p_{\cdot j}}, \dots, \frac{p_{pj}}{p_{\cdot j}} \right)'$.

行剖面 P_i^r 是单独研究矩阵 P 的第 i 行的各个取值在 q 维超平面 $x_1 + x_2 + \dots + x_q = 1$ 上的分布; 列剖面 P_j^c 是单独研究矩阵 P 的第 j 列的各个取值在 p 维超平面 $x_1 + x_2 + \dots + x_p = 1$ 上的分布; 记 p 个行剖面的集合为 P^r , q 个列剖面的集合为 P^c .

5. 属性内的加权距离:

$$D^2(P_k^r, P_l^r) = \sum_{j=1}^q \frac{\left(\frac{p_{kj}}{p_{k\cdot}} - \frac{p_{lj}}{p_{l\cdot}} \right)^2}{p_{\cdot j}}, \quad D^2(P_s^c, P_t^c) = \sum_{i=1}^p \frac{\left(\frac{p_{is}}{p_{\cdot s}} - \frac{p_{it}}{p_{\cdot t}} \right)^2}{p_{i\cdot}}$$

6. 属性 A, B 的中心:

$$\overline{P^r} = (\sqrt{p_{\cdot 1}}, \sqrt{p_{\cdot 2}}, \dots, \sqrt{p_{\cdot q}})', \quad \overline{P^c} = (\sqrt{p_{1\cdot}}, \sqrt{p_{2\cdot}}, \dots, \sqrt{p_{p\cdot}})'$$

7. 行列剖面的总惯量:

$$I_r = \sum_{i=1}^p D^2(P_i^r, \overline{P^r}), \quad I_c = \sum_{j=1}^q D^2(P_j^c, \overline{P^c})$$

【例题 1】推导总惯量表达式： $I_r = I_c = \frac{1}{n}\chi^2$ ， $n = \sum n_{ij}$ ，即总惯量不仅反映行剖面集各点与其重心加权距离的总和，同时与 χ^2 统计量仅相差常数倍，因此，总惯量也反映两个属性变量各状态之间的相关关系。

二、对应分析

1. 对应分析的目的：

在总惯量信息损失最小的前提下，简化数据结构以反映两属性变量之间的相关关系。

2. 对应分析（行列剖面的协方差矩阵）：

设各个行剖面坐标经过变换，以消除变量 B 的影响：

$$P_i^{r*} = \left(\frac{p_{i1}}{\sqrt{p_{\cdot 1} p_{i \cdot}}}, \frac{p_{i2}}{\sqrt{p_{\cdot 2} p_{i \cdot}}}, \dots, \frac{p_{iq}}{\sqrt{p_{\cdot q} p_{i \cdot}}} \right)'$$

则 p 个行剖面构成矩阵

$$P^r = \begin{bmatrix} P_1^{r*'} \\ P_2^{r*'} \\ \vdots \\ P_p^{r*'} \end{bmatrix} = \begin{bmatrix} \frac{p_{11}}{\sqrt{p_{\cdot 1} p_{1 \cdot}}} & \frac{p_{12}}{\sqrt{p_{\cdot 2} p_{1 \cdot}}} & \dots & \frac{p_{1q}}{\sqrt{p_{\cdot q} p_{1 \cdot}}} \\ \frac{p_{21}}{\sqrt{p_{\cdot 1} p_{2 \cdot}}} & \frac{p_{22}}{\sqrt{p_{\cdot 2} p_{2 \cdot}}} & \dots & \frac{p_{2q}}{\sqrt{p_{\cdot q} p_{2 \cdot}}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{p_{p1}}{\sqrt{p_{\cdot 1} p_{p \cdot}}} & \frac{p_{p2}}{\sqrt{p_{\cdot 2} p_{p \cdot}}} & \dots & \frac{p_{pq}}{\sqrt{p_{\cdot q} p_{p \cdot}}} \end{bmatrix}$$

设 P^r 的加权协方差矩阵为

$$\Sigma^r = \sum_{i=1}^p p_{i \cdot} (P_i^{r*} - \bar{P}^r)(P_i^{r*} - \bar{P}^r)'$$

则 Σ^r 有如下分解：

$$\Sigma^r = Z Z'$$

同理，列剖面形成的协方差矩阵 Σ^c 有如下分解：

$$\Sigma^c = Z' Z$$

【例题 2】求证： $\Sigma^r = Z Z'$ 。

3. 对应分析（Q 型因子分析与 R 型因子分析）：

基于行剖面与列剖面的协方差矩阵分解，对应分析可转化为对 Z 的分析，由 ZZ' 与 $(ZZ')'$ 有相同的特征值，记作 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r$ 。由

$$\Sigma^r \overline{P^r} = 0, \quad \Sigma^c \overline{P^c} = 0$$

则 Σ^r, Σ^c 分别包含以 0 为特征值对应的特征向量 $\overline{P^r}, \overline{P^c}$ ，该因子轴对于公共因子的解释无作用。于是，公共因子轴最大维数

$$0 < r \leq \min\{n, p\} - 1$$

设特征值 $\lambda_1, \lambda_2, \dots, \lambda_r$ 对应的特征向量为 $u_1, u_2, \dots, u_r$ ，则

$$\Sigma_r u_j = ZZ' u_j = \lambda_j u_j$$

且有

$$Z' ZZ' u_j = \Sigma^c Z' u_j = \lambda_j Z' u_j$$

即 $Z' u_j$ 为 Σ^c 的特征值 λ_j 对应的特征向量，故

Σ^r 的特征值 λ_j 对应的特征向量 u_j ， Σ^c 的特征值 λ_j 对应的特征向量 $Z' u_j$
--

即得 Q 型因子分析与 R 型因子分析的对等关系。

【例题 3】求证： $\Sigma^r \overline{P^r} = 0$ 。

4. 对应分析的原理：

通过 Q 型因子分析与 R 型因子分析的对等关系，将变量 B 的 q 维空间中的 r 个主因子与变量 A 的 p 维空间中相对应的各个主因子联系起来， Σ^r, Σ^c 的特征值是各个公共因子所解释的方差，其在总方差中所占比例完全相同，即可以用相同的因子轴同时表示两个属性变量的各个状态，同时反映在相同坐标轴的因子平面上。例如，对于变量 A 的状态 i ，


$$D(F_k) = \sum_{i=1}^p p_i \cdot a_{ik}^2 = \lambda_k$$

对公共因子的贡献为 $h_i^2 = \frac{p_i \cdot a_{ik}^2}{\lambda_k}$ ， h_i^2 值越大，说明状态 i 对第 k 个公共因子的贡献越大。

5. 对应分析的步骤：

- (1) 由原始列联表数据计算规格化的概率意义上的列联表；
- (2) 计算 Z 矩阵；
- (3) 由 Σ^r 或 Σ^c 出发进行 Q 型因子分析或 R 型因子分析，并相互推导；
- (4) 在二维图上画出原始变量各个状态，并对原始变量相关性进行分析。

6. 对应分析的一般方法：



三、典型相关分析的基本思想

1. 典型相关分析研究两组变量间整体的线性相关关系，将每一组变量作为一个整体进行研究，而不分析每组变量内部的各个变量。

2. 典型相关分析借助主成分分析的思想，对每组变量分别寻找线性组合，使生成的新的综合变量能代表原始变量大部分的信息，同时，与由另一组变量生成的新的综合变量的相关程度最大，称为第一对典型相关变量，同样的方法可以找到第 r 对典型相关变量，且使各对典型相关变量之间互不相关，典型相关变量之间的简单相关系数称为典型相关系数。

3. 典型相关变量的求解思想：

设 $X = (X_1, X_2, \dots, X_p)$, $Y = (Y_1, Y_2, \dots, Y_q)$ 是相关的随机变量，利用主成分分析分别选取

$$\begin{cases} U_i = a_i'x = a_{i1}X_1 + a_{i2}X_2 + \dots + a_{ip}X_p, & 1 \leq i \leq p \\ V_j = b_j'y = b_{j1}Y_1 + b_{j2}Y_2 + \dots + b_{jq}Y_q, & 1 \leq j \leq q \end{cases}$$


寻求满足下式的各对互不相关的典型相关变量：

$$r(U_k, V_k) = \max_{1 \leq i \leq p, 1 \leq j \leq q} r(U_i, V_j)$$

$$s.t. D(U_k) = D(V_k) = 1$$

4. 典型相关分析的一般步骤：

- (1) 确定典型相关分析的目标；
- (2) 设计典型相关分析；
- (3) 检验典型相关分析的基本假设；
- (4) 推导典型函数，评价整体拟合情况；
- (5) 解释典型变量，验证模型。



四、典型相关变量的求解与检验

1. 总体典型相关变量与系数的构造与求解:

设 $X = (X_1, X_2, \dots, X_p), Y = (Y_1, Y_2, \dots, Y_q)$ 是相关的随机变量, 协方差矩阵形如

$$\text{cov}(X, Y) = \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

在方差限定为1的条件下, 有

$$r(U_1, V_1) = \text{cov}(U_1, V_1) = a'_i \text{cov}(X, Y) b_j = a'_i \Sigma_{12} b_j$$

则求解第一对典型相关变量的约束优化问题转化为

$$r(U_1, V_1) = \max_{1 \leq i \leq p, 1 \leq j \leq q} a'_i \Sigma_{12} b_j$$

$$s. t. D(U_1) = D(V_1) = 1$$

构造 Lagrange 函数:

$$L(a, b; \lambda, \mu) = a' \Sigma_{12} b - \frac{\lambda}{2} (a' \Sigma_{11} a - 1) - \frac{\mu}{2} (b' \Sigma_{22} b - 1)$$

令方程组

$$\begin{cases} \frac{\partial L}{\partial a} = \Sigma_{12} b - \lambda \Sigma_{11} a = 0 \\ \frac{\partial L}{\partial b} = \Sigma'_{12} a - \mu \Sigma_{22} b = 0 \\ \frac{\partial L}{\partial \lambda} = a' \Sigma_{11} a - 1 = 0 \\ \frac{\partial L}{\partial \mu} = b' \Sigma_{22} b - 1 = 0 \end{cases}$$

解得

$$\lambda = \lambda a' \Sigma_{11} a = a' \Sigma_{12} b = (b' \Sigma'_{12} a)' = \mu b' \Sigma_{22} b = \mu$$

由 $\lambda = \mu$, 可将原方程组转化为

$$\begin{bmatrix} -\lambda \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & -\lambda \Sigma_{22} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = 0$$

有非零解的充要条件为

$$\begin{vmatrix} \lambda \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & -\lambda \Sigma_{22} \end{vmatrix} = 0$$

设 $p + q$ 个根分别为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{p+q}$, 由

$$\begin{cases} \Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} (-\lambda \Sigma_{11} a + \Sigma_{12} b) = \Sigma_{22}^{-1} (-\lambda \Sigma_{21} a + \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} b) = \Sigma_{22}^{-1} (-\lambda^2 \Sigma_{22} + \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}) b = 0 \\ \Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} (\Sigma_{21} a - \lambda \Sigma_{22} b) = \Sigma_{11}^{-1} (\Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} a - \lambda \Sigma_{12} b) = \Sigma_{11}^{-1} (\Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} - \lambda^2 \Sigma_{11}) a = 0 \end{cases}$$

即

$$\begin{cases} (\Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} - \lambda^2 E_q) b = 0 \\ (\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} - \lambda^2 E_p) a = 0 \end{cases}$$

故 λ^2 对 a 有 p 个解 $\lambda_1^2 \geq \dots \geq \lambda_p^2$, 为 $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$ 的特征值, a 为对应的特征向量;

对 b 有 q 个解 $\lambda_{p+1}^2 \geq \dots \geq \lambda_{p+q}^2$, 为 $\Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$ 的特征值, b 为对应的特征向量.

对于任意矩阵 A, B , 由 AB 与 BA 的特征值相同, 故可进行如下分解

$$\begin{cases} \Sigma_{22}^{-\frac{1}{2}} \Sigma_{21} \Sigma_{11}^{-\frac{1}{2}} \Sigma_{11}^{-\frac{1}{2}} \Sigma_{12} \Sigma_{22}^{-\frac{1}{2}} = T T' \\ \Sigma_{11}^{-\frac{1}{2}} \Sigma_{12} \Sigma_{22}^{-\frac{1}{2}} \Sigma_{22}^{-\frac{1}{2}} \Sigma_{21} \Sigma_{11}^{-\frac{1}{2}} = T' T \end{cases}$$

则 $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$ 与 $\Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$ 的特征值相同, 即均为 p 个特征值: $\lambda_1^2 \geq \dots \geq \lambda_p^2 > 0$

其中, $\lambda_{p+1}^2 = \lambda_1^2, \dots, \lambda_{2p}^2 = \lambda_p^2, \lambda_{2p+1}^2 = \dots = \lambda_{p+q}^2 = 0$.

故总体典型相关系数分别为

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$$

从而, 对于第*i*总体典型相关系数 λ_i , 满足 $r(U_i, V_i) = \lambda_i$ 的 (U_i, V_i) 即为第*i*对总体典型相关变量.

2. 总体典型相关变量的性质:

(1) 由 $X_1, X_2, \dots, X_p$ 组成的典型变量 $U_1, U_2, \dots, U_p$ 互不相关, 由 $Y_1, Y_2, \dots, Y_q$ 组成的典型变量 $V_1, V_2, \dots, V_q$ 互不相关, 且方差均为1, 即

$$\text{cov}(U_i, U_j) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}, \quad \text{cov}(V_i, V_j) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

(2) 同一对典型变量间的相关系数为 λ_i , 不同对典型变量间互不相关, 即

$$\text{cov}(U_i, V_i) = \lambda_i > 0, \quad \text{cov}(U_i, V_j) = 0$$

3. 样本典型相关系数与变量的估计:

对于总体协方差矩阵的最大似然估计为

$$\hat{\Sigma} = \frac{1}{n} \begin{bmatrix} L_{11} & L_{12} \\ L_{21} & L_{22} \end{bmatrix}$$

其中,

$$L_{11} = \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})', \quad L_{22} = \sum_{i=1}^n (y_i - \bar{y})(y_i - \bar{y})',$$

$$L_{12} = L'_{21} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})'$$

4. 第一对典型相关系数的显著性检验:

$$H_0: \lambda_1 = 0 \leftrightarrow H_1: \lambda_1 \neq 0$$

检验统计量:

$$\chi_1^2 = - \left(n - 1 - \frac{1}{2}(p + q + 1) \right) \ln \prod_{i=1}^p (1 - \lambda_i^2) \stackrel{\text{在 } H_0 \text{ 下近似地}}{\sim} \chi^2(pq)$$

拒绝域: $W = \{\chi_1^2 > \chi_{\alpha}^2(pq)\}$, 至少有第一对典型变量显著相关, λ_1 在 α 水平下显著.

5. 第*j*对典型相关系数的显著性检验:

$$H_0: \lambda_j = 0 \leftrightarrow H_1: \lambda_j \neq 0$$

检验统计量:

$$\chi_j^2 = - \left(n - j - \frac{1}{2}(p + q + 1) \right) \ln \prod_{i=j}^p (1 - \lambda_i^2) \stackrel{\text{在 } H_0 \text{ 下近似地}}{\sim} \chi^2((p - j + 1)(q - j + 1))$$

拒绝域: $W = \{\chi_j^2 > \chi_{\alpha}^2((p - j + 1)(q - j + 1))\}$, λ_j 在 α 水平下显著.

